ĐẠI HỌC ĐÀ NẴNG

TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHOA ĐIỆN TỬ - VIỄN THÔNG

BÁO CÁO
PBL4 : TRÍ TUỆ NHÂN TẠO

ĐỀ TÀI:

Nghiên cứu phân đoạn tự động nốt phổi và sinh ảnh biểu diễn tính không đồng nhất nội khối trên ảnh CT

Sinh viên thực hiện: **Lê Thành Duy**

Mã số sinh viên: **106220250**

Lớp**:** **22KTMT2**

GVHD: **TS. Trần Thị Minh Hạnh**

Đà Nẵng, 06/2026

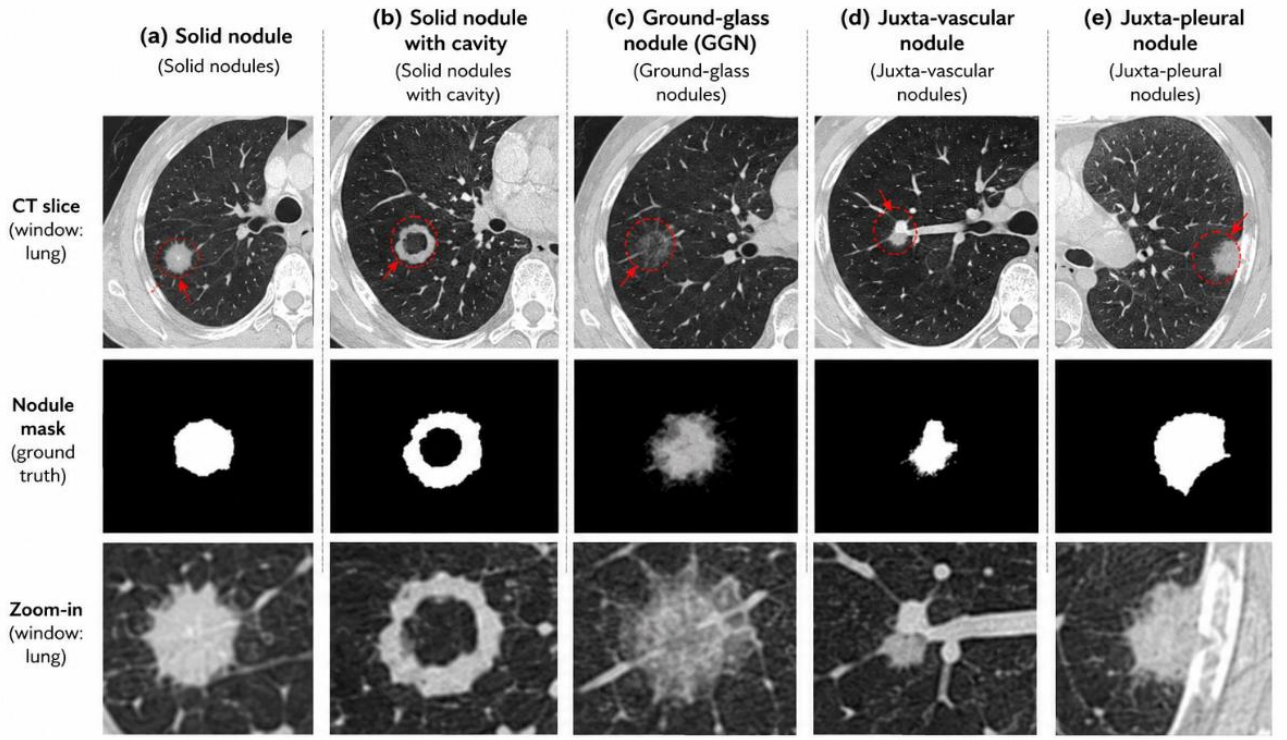
Tóm tắt: Phân đoạn tự động nốt phổi trên ảnh chụp cắt lớp vi tính (computed tomography, CT) là một nhiệm vụ quan trọng trong phân tích ảnh lồng ngực, nhưng vẫn gặp nhiều thách thức do nốt phổi có kích thước nhỏ, hình thái đa dạng, biên mờ, cường độ không đồng nhất và có thể bám vào mạch máu hoặc màng phổi. Nghiên cứu này xây dựng một hệ thống phân đoạn nốt phổi hoàn toàn tự động từ ảnh CT đầu vào, trong đó cụm ba lát CT liên tiếp được đưa qua Heatmap Detector để tạo candidate regions, Context-Aware Crop để chuẩn hóa vùng phân tích, Segmentation Refiner để sinh mặt nạ nốt, Heterogeneity Head để tạo bản đồ trực quan hóa tính không đồng nhất nội nốt, Candidate Verification/False Positive Reduction để loại ứng viên sai và Safe Fusion để tạo final nodule mask trên lát CT đầy đủ. Hệ thống không sử dụng ROI thủ công, bounding box thủ công hoặc tọa độ ground-truth trong suy luận. Đầu ra gồm mặt nạ phân đoạn nốt phổi ở không gian full-slice CT và heterogeneity map phục vụ trực quan hóa. Bản đồ heterogeneity không được sử dụng cho phân loại lành tính/ác tính và không được diễn giải như kết luận chẩn đoán.

Từ khóa: CT, lung nodule segmentation, ROI, heatmap, automatic ROI crop, WGAN-GP, intra-nodular heterogeneity, connected components, false positive reduction, safe fusion, Dice coefficient, IoU, GIoU, LIDC-IDRI.

1. Giới thiệu

Ung thư phổi là một trong những nguyên nhân gây tử vong hàng đầu do ung thư trên toàn thế giới và vẫn đang là một thách thức lớn đối với y học hiện đại. Theo thống kê GLOBOCAN 2020, ung thư phổi nằm trong nhóm bệnh ung thư có tỷ lệ mắc mới và tỷ lệ tử vong cao nhất, gây ra gánh nặng đáng kể cho hệ thống y tế cũng như chất lượng cuộc sống của người bệnh [2]. Nhiều nghiên cứu đã chỉ ra rằng khả năng sống sót của bệnh nhân có thể được cải thiện đáng kể nếu tổn thương được phát hiện ở giai đoạn sớm, khi kích thước khối u còn nhỏ và chưa xuất hiện di căn [3]. Vì vậy, việc phát hiện sớm và đánh giá chính xác các nốt phổi nghi ngờ trên ảnh y học có ý nghĩa đặc biệt quan trọng trong quá trình sàng lọc, chẩn đoán và theo dõi điều trị.

Trong thực hành lâm sàng, chụp cắt lớp vi tính ngực (Computed Tomography - CT) là phương tiện hình ảnh được sử dụng rộng rãi để phát hiện và đánh giá các tổn thương dạng nốt trong nhu mô phổi nhờ khả năng cung cấp thông tin giải phẫu chi tiết với độ phân giải cao [4]. Sự phát triển của các hệ thống hỗ trợ chẩn đoán bằng máy tính (Computer-Aided Diagnosis - CAD), radiomics và các mô hình học sâu đã mở ra nhiều cơ hội mới trong việc tự động phát hiện, phân tích và định lượng các đặc trưng của nốt phổi [5]. Những hệ thống này có thể hỗ trợ bác sĩ trong việc giảm tải khối lượng công việc, nâng cao tính nhất quán trong đánh giá hình ảnh và cải thiện độ chính xác của quá trình chẩn đoán. Tuy nhiên, hiệu quả của các phương pháp phân tích sau đó phụ thuộc đáng kể vào chất lượng của bước phân đoạn nốt phổi. Những sai lệch trong việc xác định ranh giới tổn thương có thể ảnh hưởng trực tiếp đến quá trình trích xuất đặc trưng hình thái, texture, radiomics cũng như các phân tích định lượng ở các giai đoạn tiếp theo [3]–[5].



Hình 1. Các dạng nốt phổi thường gặp và những thách thức trong phân đoạn tự động. (a) Nốt đặc (solid nodules); (b) nốt đặc có hang (solid nodules with cavity); (c) nốt kính mờ (ground-glass nodules - GGNs); (d) nốt bám mạch máu (juxta-vascular nodules); và (e) nốt bám màng phổi (juxta-pleural nodules).

Mặc dù đã đạt được nhiều tiến bộ trong những năm gần đây, phân đoạn tự động nốt phổi trên ảnh CT vẫn là một bài toán đầy thách thức [6]–[9]. Các nốt phổi có sự đa dạng lớn về kích thước, hình dạng, vị trí giải phẫu và đặc tính cường độ. Như minh họa trong Hình 1, nốt phổi có thể xuất hiện dưới nhiều dạng khác nhau như nốt đặc (solid nodule), nốt đặc có hang, nốt kính mờ (ground-glass nodule - GGN), nốt bám mạch máu (juxta-vascular nodule) hoặc nốt bám màng phổi (juxta-pleural nodule). Đặc biệt, các trường hợp juxta-vascular và juxta-pleural thường có cường độ ảnh tương đồng với các cấu trúc lân cận, khiến ranh giới giải phẫu trở nên khó xác định. Trong khi đó, các nốt kính mờ thường có độ tương phản thấp so với nhu mô phổi bình thường, gây khó khăn cho cả các phương pháp truyền thống và các mô hình học sâu. Ngoài ra, sự khác biệt về thông số chụp, độ dày lát cắt, thuật toán tái tạo ảnh và thiết lập cửa sổ hiển thị cũng có thể làm thay đổi đáng kể đặc tính hình ảnh của cùng một loại nốt. Do kích thước nốt thường chỉ chiếm một tỷ lệ rất nhỏ so với toàn bộ lát CT, bài toán còn chịu ảnh hưởng mạnh của hiện tượng mất cân bằng giữa vùng tổn thương (foreground) và vùng nền (background), làm gia tăng nguy cơ xuất hiện false positive và false negative trong quá trình huấn luyện và suy luận [6]–[9].

Bên cạnh nhiệm vụ xác định chính xác ranh giới nốt phổi, việc biểu diễn các đặc điểm bên trong tổn thương cũng nhận được nhiều sự quan tâm trong các nghiên cứu gần đây [1], [10], [11]. Tính không đồng nhất nội khối (intra-nodular heterogeneity) được xem là một đặc

điểm phản ánh sự biến thiên về cấu trúc và phân bố cường độ bên trong vùng tổn thương, từ đó cung cấp thêm thông tin hỗ trợ cho quá trình phân tích hình ảnh [10], [11]. Tuy nhiên, nhiều nghiên cứu cho thấy các đặc trưng radiomics và các chỉ số liên quan đến tính dị thể có thể chịu ảnh hưởng bởi điều kiện chụp, quy trình tiền xử lý và phương pháp trích xuất đặc trưng [12]. Vì vậy, việc xây dựng các phương pháp trực quan hóa dị thể nội nốt theo hướng tự động và ổn định vẫn là một hướng nghiên cứu có ý nghĩa trong lĩnh vực phân tích ảnh CT phổi.

Xuất phát từ những thách thức trên, nghiên cứu này đề xuất một hệ thống phân đoạn nốt phổi hoàn toàn tự động trên ảnh CT. Hệ thống nhận đầu vào là cụm ba lát CT liên tiếp (3-slice CT stack), sau đó thực hiện phát hiện vùng ứng viên bằng heatmap ROI detector, tự động tạo vùng phân tích, phân đoạn chi tiết bằng ROI segmentation refiner, sinh bản đồ intra-nodular heterogeneity phục vụ trực quan hóa, thực hiện component-level false-positive reduction và cuối cùng hợp nhất kết quả bằng cơ chế safe fusion để tạo mặt nạ nốt phổi trên toàn bộ lát CT. Toàn bộ quá trình suy luận được thực hiện theo cơ chế full-auto và không sử dụng ROI thủ công hoặc tọa độ ground-truth. Do đó, kết quả đánh giá chính của nghiên cứu được thực hiện trên toàn bộ pipeline tự động, trong khi các thí nghiệm sử dụng oracle ROI chỉ đóng vai trò tham chiếu nhằm đánh giá riêng năng lực của nhánh phân đoạn khi vị trí tổn thương đã được xác định chính xác [1].

Các đóng góp chính của nghiên cứu bao gồm: (1) xây dựng một pipeline phân đoạn nốt phổi hoàn toàn tự động từ ảnh CT đầu vào đến mặt nạ phân đoạn cuối cùng; (2) kết hợp cơ chế phát hiện vùng ứng viên, phân đoạn chi tiết và giảm false positive trong cùng một hệ thống; (3) xây dựng bản đồ intra-nodular heterogeneity phục vụ trực quan hóa đặc điểm bên trong tổn thương; và (4) đánh giá hệ thống trên bộ dữ liệu LIDC-IDRI theo thiết lập full-auto nhằm phản ánh sát hơn điều kiện vận hành thực tế.

2. Các nghiên cứu liên quan

Phân đoạn nốt phổi trên ảnh CT là một trong những bài toán quan trọng trong lĩnh vực phân tích ảnh y học và đã được nghiên cứu rộng rãi trong nhiều năm qua. Các phương pháp hiện có có thể được chia thành hai nhóm chính gồm các phương pháp truyền thống dựa trên xử lý ảnh và nhận dạng mẫu, và các phương pháp dựa trên học sâu. Mỗi hướng tiếp cận đều có những ưu điểm và hạn chế riêng khi xử lý các trường hợp nốt phổi có kích thước nhỏ, hình dạng phức tạp hoặc bám dính vào các cấu trúc giải phẫu lân cận như mạch máu và màng phổi [6]–[9].

Trong nhóm phương pháp truyền thống, các kỹ thuật như region growing, level set, graph cut, active contour và các phép toán hình thái học được sử dụng để xác định ranh giới giữa nốt phổi và mô xung quanh. Thuật toán tăng trưởng vùng ba chiều dựa trên toboggan đã được đề xuất nhằm tự động phát hiện và mở rộng vùng tổn thương theo đặc trưng cường độ ảnh [7]. Các phương pháp level set bán tự động được sử dụng để cải thiện khả năng mô hình hóa các biên phức tạp của tổn thương [8]. Ngoài ra, các kỹ thuật dựa trên convex hull, geodesic distance và selective enhancement filtering đã được nghiên cứu để xử lý các trường hợp nốt juxta-pleural hoặc juxta-vascular [14]–[16]. Weighted support vector machine cũng được áp

dụng nhằm hỗ trợ phân biệt nốt phổi với các cấu trúc nền có đặc điểm tương đồng [17]. Mặc dù có ưu điểm về khả năng diễn giải và chi phí tính toán thấp, phần lớn các phương pháp này vẫn phụ thuộc vào seed point, ROI khởi tạo hoặc các bước tiền xử lý chuyên biệt, do đó gặp nhiều hạn chế khi triển khai trong các hệ thống phân đoạn hoàn toàn tự động.

Sự phát triển của học sâu đã mang lại những bước tiến đáng kể cho bài toán phân đoạn nốt phổi. Một mô hình CNN đa tỉ lệ đã được đề xuất để thực hiện dự đoán voxel-wise trên các patch nốt được lựa chọn trước [9]. Trong số các kiến trúc hiện đại, U-Net được sử dụng rộng rãi nhờ khả năng kết hợp đặc trưng ngữ nghĩa ở mức cao với thông tin không gian ở mức thấp thông qua cơ chế skip connection [45]. Các nghiên cứu tiếp theo cho thấy nnU-Net có thể tự động cấu hình pipeline huấn luyện và đạt hiệu năng cạnh tranh trên nhiều bộ dữ liệu ảnh y sinh khác nhau [35]. Bên cạnh đó, các mô hình 3D CNN cũng chứng minh hiệu quả trong việc khai thác ngữ cảnh không gian giữa các lát CT liên tiếp để cải thiện khả năng phát hiện và phân đoạn tổn thương [40]. Tuy nhiên, nhiều hệ thống vẫn yêu cầu ROI hoặc patch được xác định trước, hoặc phải kết hợp với một module phát hiện riêng biệt để định vị vị trí nốt phổi. Song song với bài toán phân đoạn, nhiều nghiên cứu tập trung vào việc phát hiện ứng viên nốt phổi và giảm false positive. Faster R-CNN sử dụng Region Proposal Network (RPN) để thực hiện đồng thời định vị và phân loại đối tượng trong cùng một kiến trúc [31]. Phương pháp này đã được áp dụng cho ảnh CT ngực và cho thấy khả năng phát hiện nốt phổi với độ chính xác cao [18]. NoduleNet tiếp tục mở rộng hướng tiếp cận này bằng cách kết hợp candidate screening, false-positive reduction và segmentation trong một framework thống nhất [19]. Bên cạnh đó, các hàm mất mát dựa trên IoU và GIoU được đề xuất nhằm cải thiện chất lượng định vị và tối ưu hóa hộp bao trong các bài toán detection và segmentation [26], [27]. Hiệu quả của các biến thể loss này cũng đã được kiểm chứng trên nhiều bài toán thị giác máy tính và ảnh y học khác nhau [28]–[30], [32].

Một hướng nghiên cứu khác nhận được nhiều sự quan tâm trong những năm gần đây là ứng dụng Generative Adversarial Networks (GANs) vào phân đoạn và sinh ảnh y học. GAN được giới thiệu như một cơ chế học đối kháng giữa generator và discriminator nhằm mô hình hóa phân phối dữ liệu thực [23]. WGAN-GP được đề xuất nhằm cải thiện tính ổn định trong quá trình huấn luyện thông qua cơ chế gradient penalty [25]. Trong lĩnh vực ảnh CT, GAN đã được sử dụng cho nhiều nhiệm vụ như phân đoạn cơ quan, tăng cường dữ liệu, khử nhiễu ảnh liều thấp và sinh ảnh y học [20]–[23], [33]. Một số nghiên cứu còn kết hợp perceptual loss dựa trên mạng VGG để bảo toàn các đặc trưng cấu trúc và chi tiết tần số cao của ảnh [34]. Bên cạnh đó, việc biểu diễn tính không đồng nhất nội khối (intra-nodular heterogeneity) cũng được nghiên cứu như một hướng tiếp cận nhằm hỗ trợ quan sát sự biến thiên cấu trúc và texture bên trong tổn thương [1], [10], [11]. Tuy nhiên, giá trị lâm sàng của các bản đồ dị thể vẫn cần được đánh giá thêm do chịu ảnh hưởng của nhiều yếu tố như chất lượng ảnh, quy trình tiền xử lý và phương pháp trích xuất đặc trưng [12], [41]–[44].

Từ các nghiên cứu liên quan có thể nhận thấy rằng chưa có một hướng tiếp cận nào giải quyết đồng thời bài toán phát hiện ROI tự động, phân đoạn chính xác, giảm false positive và hỗ trợ biểu diễn tính không đồng nhất nội nốt trong một pipeline gọn nhẹ phù hợp với dữ liệu

CT. Dựa trên những nhận xét đó, nghiên cứu này đề xuất một hệ thống gồm heatmap ROI detector, automatic ROI crop, ROI segmentation refiner, intra-nodular heterogeneity generation, component-level false-positive reduction và safe fusion nhằm xây dựng một pipeline phân đoạn nốt phổi hoàn toàn tự động. Hệ thống được đánh giá trực tiếp trên đường suy luận full-auto và không sử dụng ROI thủ công hoặc tọa độ ground-truth trong giai đoạn inference [1].

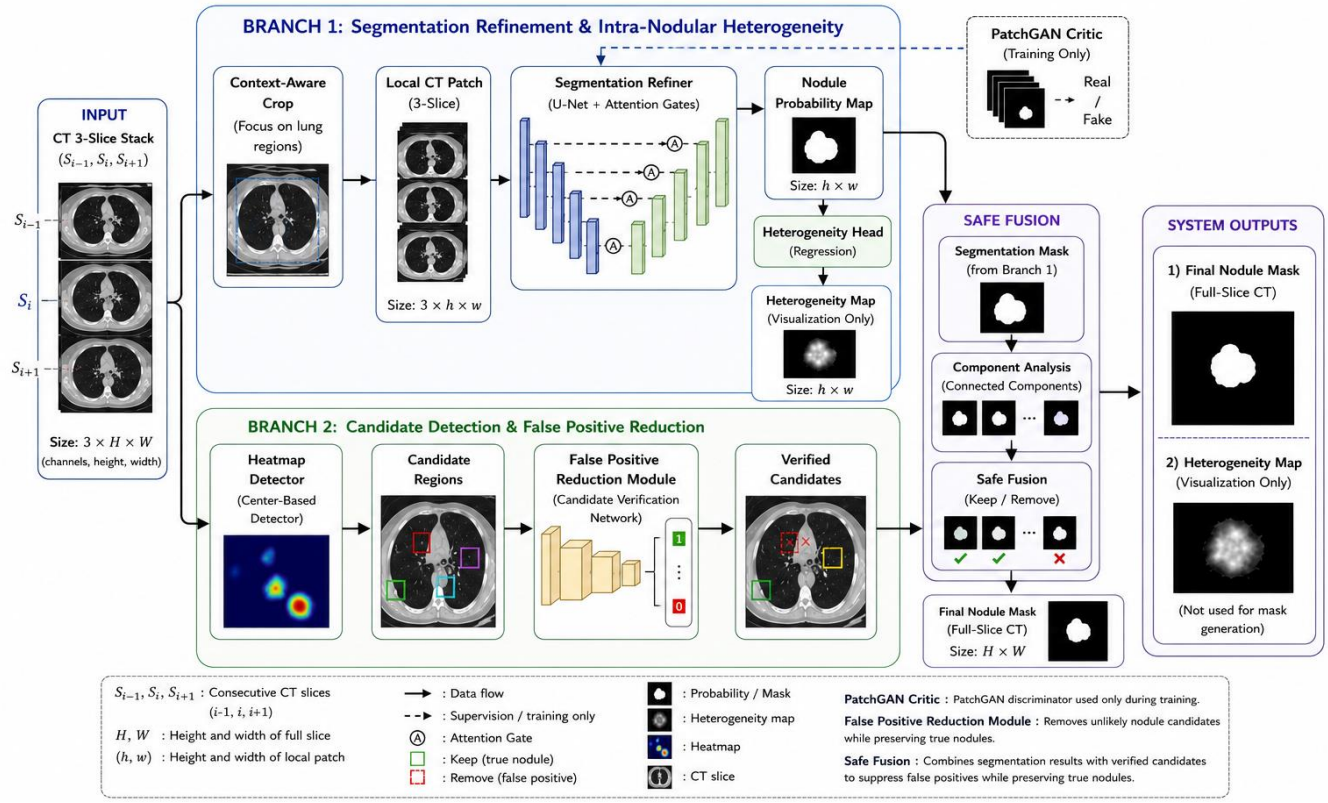
3. Phương pháp

A. Tổng quan kiến trúc hệ thống đề xuất

Hệ thống đề xuất được xây dựng nhằm thực hiện phân đoạn nốt phổi hoàn toàn tự động trên ảnh CT ngực. Khác với nhiều thiết lập chỉ đánh giá trên các vùng tổn thương được cung cấp sẵn, hệ thống được thiết kế theo hướng full-auto, trong đó toàn bộ quá trình phát hiện, định vị và phân đoạn nốt phổi đều được thực hiện trực tiếp từ dữ liệu CT đầu vào mà không yêu cầu ROI thủ công hoặc tọa độ ground-truth trong giai đoạn suy luận. Mục tiêu của hệ thống là tạo ra mặt nạ phân đoạn nốt phổi trên lát CT trung tâm đồng thời sinh bản đồ intra-nodular heterogeneity phục vụ trực quan hóa đặc điểm bên trong tổn thương.

Đầu vào của hệ thống là một cụm gồm ba lát CT liên tiếp (($S_{\{i-1\}}$, S_i,$S_{\{i+1\}}$)), trong đó (S_i) là lát trung tâm cần được phân đoạn. Ba lát được ghép theo chiều kênh để tạo thành tensor đầu vào có kích thước (3×H×W). Cách biểu diễn này cho phép mô hình khai thác thêm thông tin ngữ cảnh theo trục z từ các lát lân cận trong khi vẫn duy trì ưu điểm về chi phí tính toán của các mạng xử lý ảnh 2D. Trước khi đưa vào hệ thống, ảnh CT được chuyển đổi về đơn vị Hounsfield Unit (HU), cắt ngưỡng cường độ trong khoảng ([-1024,400]) nhằm loại bỏ các giá trị ngoài phạm vi quan tâm, sau đó chuẩn hóa về miền giá trị ([0,1]). Ground truth được xây dựng từ các annotation XML của bộ dữ liệu LIDC-IDRI dưới dạng mặt nạ nhị phân tương ứng với lát CT trung tâm.

Đầu ra cuối cùng của hệ thống gồm hai thành phần. Thành phần thứ nhất là mặt nạ phân đoạn nốt phổi trên toàn bộ lát CT trung tâm, được sử dụng để đánh giá hiệu năng của mô hình thông qua các chỉ số như Dice coefficient, IoU và Boundary F1-score. Thành phần thứ hai là bản đồ intra-nodular heterogeneity, được tạo ra từ nhánh WGAN-GP nhằm trực quan hóa sự biến thiên cấu trúc bên trong vùng nốt phổi. Trong nghiên cứu này, bản đồ heterogeneity chỉ được sử dụng cho mục đích trực quan hóa và hỗ trợ phân tích định tính, không được xem là một chỉ số chẩn đoán hoặc tiên lượng lâm sàng.



Hình 2. Kiến trúc tổng thể của hệ thống phân đoạn nốt phổi tự động đề xuất.

Kiến trúc tổng thể của hệ thống được trình bày trong Hình 2. Hệ thống bao gồm hai nhánh chức năng chính hoạt động song song trên cùng dữ liệu đầu vào. Nhánh thứ nhất đảm nhiệm nhiệm vụ phân đoạn nốt phổi và sinh bản đồ intra-nodular heterogeneity, trong khi nhánh thứ hai thực hiện phát hiện vùng ứng viên và giảm false positive. Kết quả từ hai nhánh được tổng hợp thông qua cơ chế safe fusion để tạo ra mặt nạ phân đoạn cuối cùng.

Trong nhánh thứ nhất, dữ liệu CT đầu vào được sử dụng để tạo vùng cục bộ chứa tổn thương tiềm năng và đưa vào mô hình Segmentation Refiner. Thành phần này sử dụng kiến trúc encoder–decoder kết hợp attention gates nhằm học đồng thời thông tin ngữ nghĩa và chi tiết biên của nốt phổi. Đầu ra của nhánh là bản đồ xác suất nốt phổi (nodule probability map). Từ bản đồ xác suất này, một nhánh phụ Heterogeneity Head được sử dụng để sinh bản đồ intra-nodular heterogeneity nhằm biểu diễn sự biến thiên cấu trúc bên trong vùng tổn thương. Trong quá trình huấn luyện, PatchGAN Critic được sử dụng như một thành phần đối kháng nhằm cải thiện tính nhất quán hình thái của kết quả phân đoạn. Tuy nhiên, thành phần này chỉ tham gia trong giai đoạn huấn luyện và không xuất hiện trong quá trình suy luận.

Nhánh thứ hai thực hiện phát hiện vùng ứng viên trên toàn bộ lát CT thông qua Heatmap Detector. Mô hình này sinh bản đồ nhiệt biểu diễn xác suất xuất hiện nốt phổi tại các vị trí khác nhau trên ảnh. Từ các vùng có xác suất cao, hệ thống tạo tập các ứng viên tổn thương (candidate regions). Các ứng viên sau đó được đánh giá bởi False Positive Reduction Module

nhằm loại bỏ các vùng nền hoặc cấu trúc giải phẫu có đặc điểm tương tự nốt phổi. Kết quả của bước này là tập các ứng viên đã được xác thực (verified candidates), đóng vai trò thông tin hỗ trợ cho giai đoạn hợp nhất cuối cùng.

Sau khi hoàn thành phân đoạn và phát hiện ứng viên, hệ thống thực hiện cơ chế Safe Fusion để tạo mặt nạ cuối cùng. Trước tiên, các thành phần liên thông (connected components) được trích xuất từ kết quả phân đoạn. Thông tin từ các ứng viên đã được xác thực được sử dụng để đánh giá và sàng lọc các thành phần này nhằm giảm số lượng false positive nhưng vẫn duy trì khả năng bảo toàn các vùng nốt thực. Kết quả của bước hợp nhất là mặt nạ nốt phổi cuối cùng trên lát CT trung tâm. Đồng thời, bản đồ intra-nodular heterogeneity được xuất ra như một sản phẩm trực quan hóa độc lập và không tham gia trực tiếp vào quá trình tạo mặt nạ phân đoạn.

Để làm rõ vai trò của từng thành phần trong hệ thống, Bảng 1 trình bày đầu vào, đầu ra và chức năng của các khối xử lý chính. Các thành phần của hai nhánh cũng như cơ chế Safe Fusion sẽ được trình bày chi tiết trong các mục tiếp theo.

Bảng 1. Vai trò của các khối trong hệ thống đề xuất.

Khối chức năng	**Đầu vào**	**Đầu ra**	**Vai trò**
Segmentation Refinement Branch	CT 3-slice	Nodule Probability Map	Phân đoạn nốt phổi và xác định ranh giới tổn thương
Heterogeneity Generation Branch	Đặc trưng từ nhánh phân đoạn	Heterogeneity Map	Sinh bản đồ biểu diễn tính không đồng nhất bên trong nốt phổi phục vụ trực quan hóa
Candidate Detection Branch	CT 3-slice	Candidate Regions	Phát hiện các vùng có khả năng chứa nốt phổi trên toàn bộ lát CT
False Positive Reduction Module	Candidate Regions	Verified Candidates	Loại bỏ các ứng viên không tương ứng với nốt phổi thực nhằm giảm false positive
Safe Fusion Module	Segmentation Mask và Verified Candidates	Final Nodule Mask	Hợp nhất kết quả từ hai nhánh để tạo mặt nạ phân đoạn cuối cùng

Như trình bày trong Bảng 1, hệ thống được xây dựng theo kiến trúc hai nhánh bổ trợ lẫn nhau. Nhánh phân đoạn tập trung vào việc xác định chính xác ranh giới tổn thương và sinh bản đồ heterogeneity, trong khi nhánh phát hiện và giảm false positive cung cấp cơ chế xác thực nhằm hạn chế các dự đoán sai. Kết quả từ hai nhánh được kết hợp thông qua Safe Fusion để tạo mặt nạ nốt phổi cuối cùng trên lát CT trung tâm. Các thành phần của từng nhánh cũng như cơ chế fusion sẽ được trình bày chi tiết trong các mục tiếp theo.

B. Generative Adversarial Network và WGAN-GP

Generative Adversarial Network (GAN) là mô hình học sinh dữ liệu dựa trên cơ chế đối kháng giữa hai mạng nơ-ron: Generator và Discriminator. Generator học ánh xạ từ dữ liệu đầu vào sang không gian đầu ra mong muốn, trong khi Discriminator học phân biệt giữa dữ liệu tham chiếu và dữ liệu sinh. Trong bài toán phân đoạn nốt phổi, cơ chế đối kháng được sử dụng để bổ sung ràng buộc hình thái cho mặt nạ dự đoán, giúp kết quả không chỉ tối ưu theo từng điểm ảnh mà còn phù hợp hơn với phân phối hình dạng của nốt phổi [23].

Với ký hiệu G là Generator, D là Discriminator, p_{data} là phân phối dữ liệu tham chiếu và p_z là phân phối biến ẩn, hàm mục tiêu minimax của GAN được viết như sau:

$$\min_{G}\max_{D} V(D,G) = E_{\{x\sim p_{data}\}}[\log D(x)] + E_{\{z\sim p_z\}}[\log(1 - D(G(z)))] \quad (3)$$

Trong (3), Discriminator được tối ưu để gán điểm cao cho dữ liệu thật và điểm thấp cho dữ liệu sinh, còn Generator được tối ưu theo hướng làm cho dữ liệu sinh khó bị phân biệt. Cơ chế này tạo ra tín hiệu học ở mức phân phối, có ích trong các bài toán mà loss chồng lấp thuần túy có thể bỏ qua tính liên tục hình thái hoặc cấu trúc biên nhỏ.

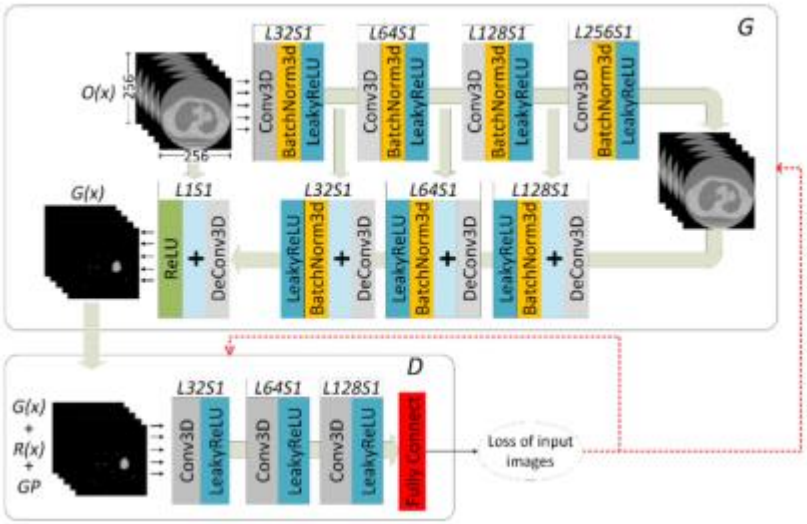
GAN nguyên bản thường khó huấn luyện ổn định. Khi Discriminator hội tụ nhanh hơn Generator, gradient truyền về Generator có thể suy giảm, gây hiện tượng gradient vanishing. Ngoài ra, khoảng cách Jensen-Shannon trong GAN cổ điển có thể không phản ánh tốt độ gần giữa hai phân phối khi chúng ít giao nhau, dẫn đến dao động huấn luyện hoặc mode collapse. Những hạn chế này đặc biệt bất lợi trong ảnh y học, nơi foreground nhỏ, biên tổn thương mờ và số lượng mẫu dương hạn chế.

Wasserstein GAN (WGAN) thay thế mục tiêu phân loại bằng ước lượng khoảng cách Wasserstein giữa phân phối thật và phân phối sinh [24]. Cách tiếp cận này cung cấp tín hiệu tối ưu mượt hơn khi hai phân phối chưa chồng lấp đáng kể. Tuy nhiên, WGAN yêu cầu Critic thỏa điều kiện Lipschitz. Kỹ thuật weight clipping trong WGAN ban đầu có thể làm giảm năng lực biểu diễn của Critic, do đó WGAN-GP bổ sung gradient penalty để ràng buộc chuẩn gradient quanh các điểm nội suy giữa mẫu thật và mẫu sinh [25].

Hàm mục tiêu WGAN-GP được sử dụng trong hệ thống có dạng:

$$\min_G \max_D L(D,G) = -E_{\{x\sim P_r\}}[D(x)] + E_{\{\tilde{x}\sim P_g\}}[D(\tilde{x})] + \lambda E_{\{\hat{x}\sim P_{\hat{x}}\}}[(||\nabla_{\{\hat{x}\}}D(\hat{x})||_2 - 1)^2] \quad (4)$$

Trong (4), P_r là phân phối dữ liệu tham chiếu, P_g là phân phối dữ liệu sinh, x̃ là đầu ra của Generator và x̂ là mẫu nội suy giữa dữ liệu thật và dữ liệu sinh. Hệ số λ điều chỉnh mức ảnh hưởng của gradient penalty. Thành phần gradient penalty buộc chuẩn gradient của Critic gần 1 tại các điểm nội suy, qua đó cải thiện tính ổn định huấn luyện mà không cần weight clipping.



Hình 3. Kiến trúc WGAN-GP được sử dụng trong nhánh phân đoạn và sinh bản đồ heterogeneity.

Như minh họa trong Hình 3, mô hình WGAN-GP bao gồm hai thành phần chính là Generator Gvà Critic D. Generator nhận ảnh CT đầu vào $O(x)$và học ánh xạ từ ảnh CT sang không gian phân đoạn để tạo ra kết quả dự đoán $G(x)$. Trong khi đó, Critic nhận đồng thời dữ liệu tham chiếu $R(x)$và dữ liệu được sinh bởi Generator nhằm đánh giá mức độ khác biệt giữa hai phân phối dữ liệu trong quá trình huấn luyện.

Generator được xây dựng theo kiến trúc encoder–decoder đối xứng. Nhánh encoder bao gồm bốn khối tích chập 3D liên tiếp với số lượng đặc trưng lần lượt là 32, 64, 128 và 256. Mỗi khối bao gồm lớp tích chập 3D, Batch Normalization và hàm kích hoạt LeakyReLU. Thông qua các lớp này, mô hình học được các đặc trưng hình thái của nốt phổi ở nhiều mức trừu tượng khác nhau. Các đặc trưng sau đó được truyền sang nhánh decoder thông qua các kết nối tắt (skip connections), giúp bảo toàn thông tin không gian và cải thiện khả năng tái tạo biên tổn thương. Nhánh decoder gồm bốn lớp giải chập 3D (DeConv3D) với số lượng đặc trưng giảm dần từ 256 xuống 32. Sau mỗi lớp giải chập, đầu ra được kết hợp với đặc trưng tương ứng từ encoder nhằm phục hồi dần độ phân giải không gian của ảnh. Lớp cuối cùng sử dụng hàm kích hoạt ReLU để tạo bản đồ dự đoán $G(x)$có cùng kích thước với ảnh đầu vào.

Critic D được thiết kế như một mạng tích chập sâu có nhiệm vụ đánh giá chất lượng của kết quả sinh ra. Đầu vào của Critic là tổng từng phần tử giữa dữ liệu tham chiếu $R(x)$ và dữ liệu dự đoán $G(x)$, kết hợp với thành phần gradient penalty. Mạng Critic bao gồm ba lớp tích

chập 3D với số lượng bộ lọc lần lượt là 32, 64 và 128. Kích thước kernel được thiết lập là $3 \times 3 \times 3$ và stride bằng 1 cho tất cả các lớp tích chập. Sau mỗi lớp tích chập, hàm kích hoạt LeakyReLU được sử dụng để tăng khả năng học các đặc trưng phi tuyến. Cuối cùng, một lớp fully connected được sử dụng để sinh giá trị đánh giá phục vụ tính toán khoảng cách Wasserstein.

Trong quá trình huấn luyện, Generator và Critic được tối ưu đồng thời thông qua hàm mất mát WGAN-GP. Critic học cách phân biệt giữa dữ liệu thực và dữ liệu dự đoán, trong khi Generator cố gắng tạo ra các kết quả có phân phối gần với dữ liệu tham chiếu. Cơ chế đối kháng này giúp mô hình không chỉ tối ưu sai số điểm ảnh mà còn học được các đặc trưng hình thái của nốt phổi, từ đó cải thiện chất lượng phân đoạn và hỗ trợ quá trình sinh bản đồ intra-nodular heterogeneity.

Trong hệ thống đề xuất, WGAN-GP được tích hợp ở mức ROI sau khi vùng ứng viên được tạo bởi nhánh phát hiện. Generator nhận patch CT ba lát và sinh đồng thời bản đồ xác suất nốt phổi cùng bản đồ heterogeneity. PatchGAN Critic đánh giá các vùng cục bộ của mặt nạ thay vì chỉ đưa ra một quyết định toàn cục. Thiết kế này phù hợp với phân đoạn nốt phổi vì lỗi biên và lỗi thành phần nhỏ thường mang tính cục bộ, trong khi toàn bộ mask chỉ chiếm diện tích rất nhỏ so với ảnh CT. Bản đồ heterogeneity được sinh từ đặc trưng học được của nhánh phân đoạn và được giới hạn trong vùng nốt dự đoán. Đầu ra này chỉ được sử dụng như một lớp trực quan hóa nhằm biểu diễn sự biến thiên tương đối trong nội vùng nốt. Hệ thống không sử dụng heterogeneity map để phân loại lành tính/ác tính, không đưa ra kết luận chẩn đoán và không được xem là công cụ lâm sàng hoàn chỉnh.

C. Intersection over Union và Generalized IoU

Intersection over Union (IoU) là thước đo chồng lấp được sử dụng rộng rãi trong detection và segmentation. Trong nhánh phát hiện ứng viên, IoU đánh giá mức giao nhau giữa vùng/hộp tham chiếu và vùng/hộp dự đoán. Trong nhánh phân đoạn, IoU được tính trực tiếp trên mặt nạ nhị phân để đo mức độ trùng khớp giữa vùng nốt dự đoán và mặt nạ tham chiếu.

$$\mathrm{IoU}(\mathrm{B_r}, \mathrm{B_p}) = \frac{|\mathrm{B_r} \cap \mathrm{B_p}|}{|\mathrm{B_r} \cup \mathrm{B_p}|} \quad (5)$$

Trong (5), B_r và B_p lần lượt là vùng tham chiếu và vùng dự đoán. IoU nhận giá trị trong khoảng từ 0 đến 1, trong đó giá trị 1 biểu thị hai vùng trùng nhau hoàn toàn. Khi hai vùng không giao nhau, IoU bằng 0 và không cung cấp thông tin về khoảng cách tương đối giữa chúng, điều này làm giảm hiệu quả tối ưu hóa trong các bài toán định vị.

Generalized IoU (GIoU) mở rộng IoU bằng cách xét thêm vùng bao nhỏ nhất C chứa đồng thời) B_r và B_p [27]. Nhờ thành phần phạt dựa trên phần diện tích không thuộc hợp của hai vùng, GIoU vẫn phản ánh quan hệ hình học ngay cả khi hai vùng chưa giao nhau.

$$\mathrm{GIoU} = \mathrm{IoU} - \frac{\left|C \,/\, \left(B_r \cup B_p\right)\right|}{|C|}, \quad L_{\mathrm{GIoU}} = 1 - \mathrm{GIoU} \quad (6)$$

Trong hệ thống đề xuất, IoU và GIoU không chỉ là metric báo cáo mà còn là cơ sở để phân tích chất lượng candidate regions. IoU thấp ở nhánh detector có thể làm giảm Dice cuối cùng dù Segmentation Refiner hoạt động tốt, trong khi IoU cao cho thấy vùng crop tự động đã bao phủ đủ nốt và ngữ cảnh lân cận.

D. Candidate Detection và False Positive Reduction

Nhánh phát hiện ứng viên nhận trực tiếp cụm ba lát CT ở kích thước full-slice và sinh bản đồ nhiệt biểu diễn xác suất xuất hiện tâm nốt tại từng vị trí. Từ bản đồ này, các đỉnh có xác suất cao được chọn làm candidate regions. Mỗi candidate được chuyển thành vùng crop có ngữ cảnh, sau đó đưa vào Segmentation Refiner để tạo mặt nạ chi tiết. Cơ chế này loại bỏ yêu cầu chọn ROI thủ công và không sử dụng tọa độ ground-truth trong suy luận.

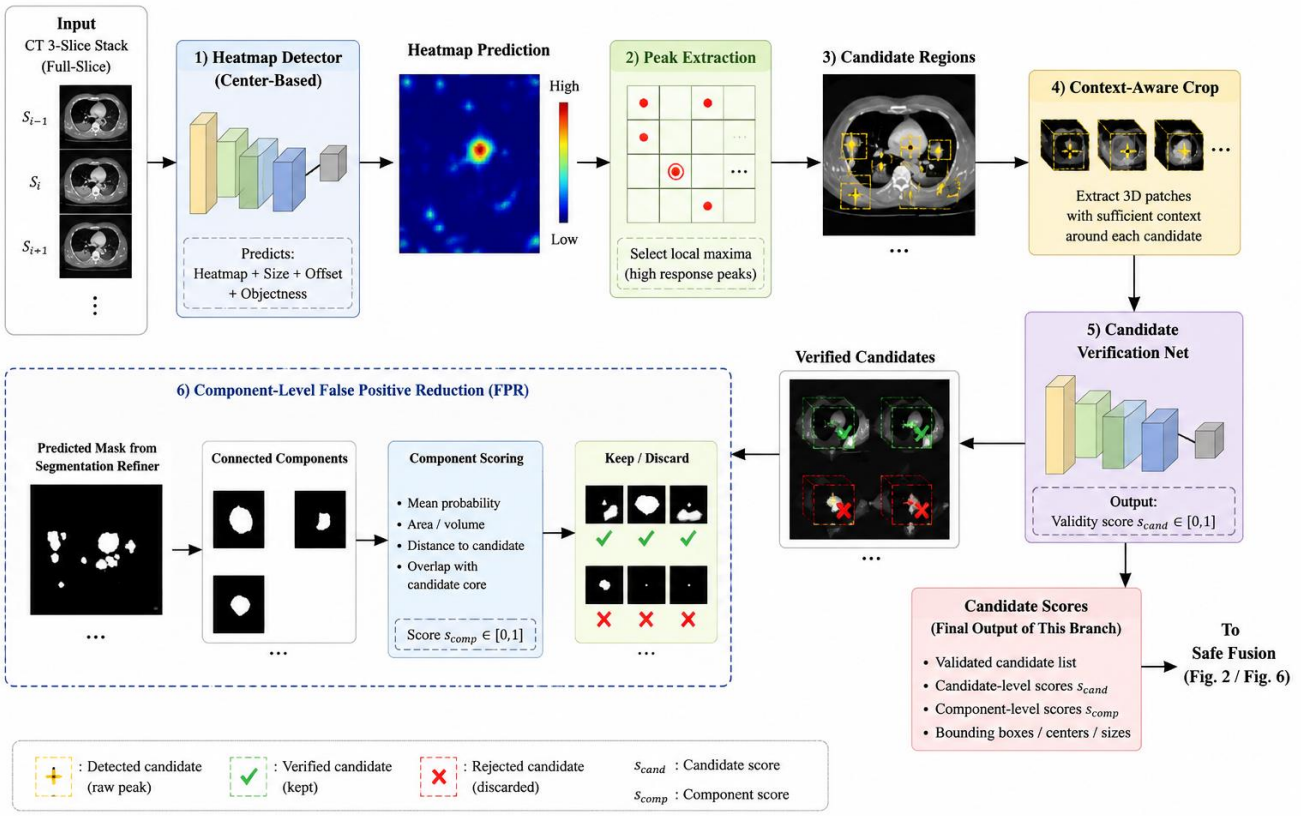
Nhánh phát hiện ứng viên nhận đầu vào trực tiếp từ cụm ba lát CT liên tiếp ở kích thước full-slice và thực hiện bài toán định vị nốt phổi trên toàn bộ trường nhìn của ảnh. Mục tiêu của nhánh này là xác định các vị trí có khả năng chứa nốt phổi mà không cần bất kỳ thông tin ROI thủ công hoặc tọa độ ground-truth nào trong giai đoạn suy luận. Để thực hiện điều đó, hệ thống sử dụng một Heatmap Detector theo hướng center-based nhằm dự đoán bản đồ nhiệt biểu diễn xác suất xuất hiện tâm nốt tại từng vị trí trên ảnh CT.

Từ bản đồ nhiệt được sinh ra, các điểm có xác suất cao nhất sẽ được lựa chọn làm các ứng viên tổn thương (candidate regions). Bên cạnh vị trí tâm, detector còn dự đoán các thông tin phụ như kích thước tương đối của vùng ứng viên, độ lệch cục bộ (offset) và điểm objectness nhằm tăng độ chính xác trong quá trình xác định vị trí nốt. Các thông tin này được kết hợp để chuyển đổi các đáp ứng trên heatmap thành tập các vùng ứng viên có khả năng chứa nốt phổi thực.

$$Y_h(u, v) = \exp\left(-\frac{(u - u_c)^2 + (v - v_c)^2}{2\sigma^2}\right) \quad (7)$$

Trong (7), Y_h là heatmap mục tiêu, (u_c , v_c) là tọa độ tâm nốt trên lưới detector và σ điều khiển độ lan của phân phối Gaussian. Bên cạnh heatmap, detector còn dự đoán các thông tin phụ như kích thước tương đối, offset cục bộ và objectness nhằm chuyển điểm đáp ứng thành vùng ứng viên có khả năng chứa nốt.

False positive là một vấn đề đáng kể trong phân đoạn nốt phổi vì mạch máu nhỏ, vùng bám màng phổi, nhiễu ảnh và các cấu trúc có cường độ tương tự nốt có thể tạo ra đáp ứng sai. Hệ thống sử dụng Candidate Verification và False Positive Reduction (FPR) ở hai mức. Ở mức candidate, mô hình đánh giá vùng ứng viên do detector tạo ra. Ở mức component, các thành phần liên thông trong mặt nạ dự đoán được chấm điểm dựa trên xác suất, diện tích, vị trí tương đối so với candidate và mức độ phù hợp với vùng lõi tin cậy.



Hình 4. Kiến trúc nhánh phát hiện ứng viên và giảm false positive.

Kiến trúc của nhánh phát hiện ứng viên và giảm false positive được trình bày trong Hình 4. Nhánh này có nhiệm vụ xác định các vị trí có khả năng chứa nốt phổi trên toàn bộ lát CT và cung cấp thông tin xác thực cho quá trình hợp nhất kết quả ở giai đoạn cuối. Không giống các phương pháp yêu cầu vị trí nốt được cung cấp trước, toàn bộ quá trình phát hiện ứng viên trong nghiên cứu được thực hiện hoàn toàn tự động từ ảnh CT đầu vào.

Đầu vào của nhánh là cụm ba lát CT liên tiếp (S_{i-1}, S_i, S_{i+1})ở kích thước full-slice. Dữ liệu được đưa vào Heatmap Detector để dự đoán bản đồ nhiệt biểu diễn xác suất xuất hiện tâm nốt trên lát CT trung tâm. Thay vì dự đoán trực tiếp mặt nạ phân đoạn, mô hình học cách xác định các vị trí có khả năng chứa nốt dựa trên thông tin ngữ cảnh cục bộ và toàn cục của ảnh CT. Ngoài heatmap, detector còn dự đoán các thông tin phụ như kích thước tương đối của nốt, độ lệch vị trí cục bộ (offset) và điểm objectness nhằm hỗ trợ quá trình sinh vùng ứng viên.

Sau khi heatmap được tạo ra, các điểm cực đại cục bộ (local maxima) có giá trị đáp ứng cao được lựa chọn thông qua bước peak extraction. Mỗi điểm cực đại tương ứng với một ứng viên tiềm năng của nốt phổi. Từ các vị trí này, hệ thống tạo các candidate regions trên lát CT và xây dựng các vùng crop có đủ ngữ cảnh xung quanh tổn thương. Việc sử dụng vùng ngữ cảnh giúp mô hình khai thác đồng thời thông tin của nốt và các cấu trúc giải phẫu lân cận, từ đó cải thiện khả năng phân biệt giữa nốt thật và các cấu trúc dễ gây nhầm lẫn.

Các vùng ứng viên sau đó được đưa vào Candidate Verification Network để đánh giá độ tin cậy. Mô hình này thực hiện phân loại từng ứng viên và sinh ra điểm xác thực $s_{cand} \in [0,1]$, phản ánh xác suất ứng viên tương ứng với một nốt phổi thực. Những ứng viên có điểm tin cậy thấp sẽ bị loại bỏ, trong khi các ứng viên có độ tin cậy cao được giữ lại dưới dạng verified candidates. Bước xác thực này giúp giảm đáng kể số lượng vùng nền, mạch máu nhỏ hoặc các cấu trúc giải phẫu khác bị detector nhận diện nhầm là nốt phổi.

Bên cạnh xác thực ở mức ứng viên, hệ thống còn thực hiện giảm false positive ở mức thành phần liên thông (component-level false positive reduction). Các thành phần liên thông được trích xuất từ mặt nạ dự đoán của nhánh phân đoạn và được đánh giá dựa trên nhiều đặc trưng khác nhau như xác suất trung bình của thành phần, kích thước, vị trí tương đối so với vùng ứng viên đã xác thực và mức độ chồng lấp với vùng lõi có độ tin cậy cao. Từ các đặc trưng này, hệ thống tính toán điểm thành phần s_{comp}để quyết định giữ lại hoặc loại bỏ từng vùng dự đoán.

Kết quả đầu ra của nhánh bao gồm danh sách các ứng viên đã được xác thực, điểm tin cậy ở mức ứng viên s_{cand}, điểm đánh giá ở mức thành phần s_{comp}cùng các thông tin hình học liên quan như vị trí tâm và kích thước vùng ứng viên. Các thông tin này không trực tiếp tạo ra mặt nạ phân đoạn cuối cùng mà được chuyển tới cơ chế Safe Fusion để kết hợp với kết quả của nhánh phân đoạn. Nhờ đó, hệ thống có thể giảm số lượng false positive trong khi vẫn duy trì khả năng bảo toàn các nốt phổi thực có kích thước nhỏ hoặc hình dạng phức tạp.

Bảng 2. Các nguồn false positive và cơ chế kiểm soát trong hệ thống.

Nguồn false positive	Nguyên nhân	Cơ chế kiểm soát
Mạch máu nhỏ	Cường độ và hình dạng gần nốt	Heatmap detector, candidate verification, component score
Vùng bám màng phổi	Biên nốt và màng phổi khó tách	Context-aware crop, boundary loss, Safe Fusion
Nhiễu hoặc artifact	Đáp ứng xác suất rời rạc	Post-processing và lọc component nhỏ
Background/no-annotated-nodule slices	Không có nốt được chú thích	Objectness, negative samples, specificity evaluation
Mask phụ ngoài vùng chính	Refiner hoặc WGAN sinh vùng phụ	Component-level FPR và giới hạn số component giữ lại

Bảng 2 cho thấy hiện tượng false positive trong bài toán phân đoạn nốt phổi có thể xuất phát từ nhiều nguồn khác nhau, bao gồm các cấu trúc giải phẫu bình thường như mạch máu nhỏ, vùng tiếp giáp màng phổi, các nhiễu ảnh phát sinh trong quá trình chụp CT hoặc các vùng không chứa nốt nhưng có đặc điểm cường độ tương tự tổn thương. Những yếu tố này có thể tạo ra các đáp ứng sai trong cả giai đoạn phát hiện ứng viên lẫn giai đoạn phân đoạn.

Để hạn chế các trường hợp dự đoán sai, hệ thống đề xuất áp dụng cơ chế giảm false positive ở nhiều mức khác nhau. Heatmap Detector và Candidate Verification Network được sử dụng để kiểm soát chất lượng của các vùng ứng viên ngay từ giai đoạn đầu. Trong khi đó,

component-level FPR đánh giá trực tiếp các thành phần liên thông của mặt nạ dự đoán dựa trên xác suất, kích thước và tính nhất quán không gian. Cuối cùng, cơ chế Safe Fusion kết hợp thông tin từ nhánh phân đoạn và nhánh phát hiện nhằm loại bỏ các thành phần có độ tin cậy thấp nhưng vẫn duy trì khả năng bảo toàn các nốt phổi thực.

Nhờ cơ chế kiểm soát nhiều tầng như vậy, hệ thống không chỉ tập trung vào việc giảm số lượng false positive mà còn hướng tới cân bằng giữa độ nhạy (sensitivity) và độ đặc hiệu (specificity). Điều này đặc biệt quan trọng đối với các nốt phổi kích thước nhỏ hoặc có hình dạng phức tạp, nơi việc loại bỏ quá mức các vùng nghi ngờ có thể dẫn đến gia tăng false negative và làm suy giảm hiệu năng phân đoạn của toàn hệ thống.

E. Hàm mất mát

Hàm mất mát của hệ thống được thiết kế phù hợp với từng thành phần chức năng trong pipeline. Do nốt phổi thường chiếm diện tích nhỏ so với nền ảnh CT, bài toán phân đoạn chịu ảnh hưởng mạnh của mất cân bằng foreground/background, biên tổn thương mờ và kích thước nốt nhỏ. Vì vậy, nhánh Segmentation Refiner sử dụng tổ hợp nhiều thành phần loss nhằm tối ưu đồng thời độ chồng lấp, độ nhạy với foreground và chất lượng biên.

Dice loss được xây dựng từ Dice coefficient giữa mặt nạ tham chiếu và xác suất dự đoán:

$$Dice(R,P) = \frac{2\sum R(x,y)P(x,y) + \varepsilon}{\sum R(x,y) + \sum P(x,y) + \varepsilon}, \quad L_{Dice} = 1 - Dice \quad (8)$$

Trong đó ε là hằng số nhỏ nhằm tránh chia cho 0. Dice loss giúp tối ưu trực tiếp mức độ chồng lấp giữa mặt nạ dự đoán và mặt nạ tham chiếu.

Weighted Binary Cross-Entropy được sử dụng để tăng ảnh hưởng của các pixel thuộc vùng nốt trong bối cảnh foreground nhỏ hơn nhiều so với background:

$$L_{BCE} = -\frac{1}{N}\sum[w\,R\,log(P) + (1 - R)\,log(1 - P)] \quad (9)$$

Trong đó w là trọng số foreground được tính theo tỷ lệ giữa số pixel nền và số pixel nốt, có giới hạn trên để tránh mất ổn định huấn luyện.

Focal loss được sử dụng nhằm tăng trọng số cho các điểm khó phân loại và giảm ảnh hưởng của các pixel nền dễ:

$$L_{Focal} = -\alpha_t(1 - p_t)^{\gamma}\,log(p_t) \quad (10)$$

Trong đó p_t là xác suất dự đoán tương ứng với nhãn đúng, α_t là hệ số cân bằng lớp và γ là tham số điều chỉnh mức tập trung vào các mẫu khó [44].

Tversky loss được sử dụng để điều chỉnh mức phạt giữa false positive và false negative:

$$L_{Tversky} = (1 - \frac{TP + \varepsilon}{TP + \alpha FP + \beta FN + \varepsilon})^{\gamma} \quad (11)$$

Trong đó TP, FP và FN lần lượt là true positive, false positive và false negative. Trong bài toán nốt phổi nhỏ, việc kiểm soát false negative có ý nghĩa quan trọng vì bỏ sót nốt có thể làm giảm đáng kể hiệu năng của toàn bộ hệ thống [45].

Boundary Dice loss được sử dụng để tăng độ nhạy của mô hình đối với vùng biên tổn thương:

$$L_{Boundary} = 1 - \frac{2\sum B(R)B(P) + \varepsilon}{\sum B(R) + \sum B(P) + \varepsilon} \quad (12)$$

Trong đó B(·) là toán tử trích biên dựa trên dilation và erosion. Thành phần này giúp mô hình chú ý tốt hơn đến ranh giới nốt phổi, đặc biệt trong các trường hợp nốt có biên mờ hoặc tiếp giáp với mạch máu và màng phổi.

Hàm mất mát tổng hợp của nhánh Segmentation Refiner được định nghĩa như sau:

$$L_{refiner} = \lambda_1 L_{BCE} + \lambda_2 L_{Focal} + \lambda_3 L_{Dice} + \lambda_4 L_{Tversky} + \lambda_5 L_{Boundary} \quad (13)$$

Trong đó λ_1, λ_2, λ_3, λ_4 và λ_5 là các hệ số trọng số tương ứng với từng thành phần loss. Trong cấu hình huấn luyện hiện tại, các trọng số này lần lượt tương ứng với W_BCE, W_FOCAL, W_DICE, W_TVERSKY và W_BOUNDARY.

Đối với nhánh ROI-WGAN, Generator được tối ưu bằng tổ hợp giữa loss phân đoạn, loss đối kháng và các thành phần phụ trợ nhằm cải thiện chất lượng mặt nạ cũng như bản đồ heterogeneity. Hàm mất mát của Generator được biểu diễn tổng quát như sau:

$$L_G = \beta_1 L_{BCE} + \beta_2 L_{Dice} + \beta_3 L_{Tversky} + \beta_4 L_{Boundary} + \beta_5 L_{MSE} + \beta_6 L_{Edge} + \beta_7 L_{Teacher} + \beta_8 L_{Adv} + \beta_9 L_{Hetero} \quad (14)$$

Trong đó L_{MSE} tối ưu sai số điểm ảnh giữa xác suất dự đoán và mặt nạ tham chiếu, L_{Edge} là edge reconstruction loss dựa trên biên ảnh, $L_{Teacher}$ là teacher consistency loss giữa Generator và Segmentation Refiner, L_{Adv} là adversarial loss từ PatchGAN Critic, và L_Hetero là thành phần regularization dùng để làm mượt bản đồ heterogeneity đồng thời hạn chế rò tín hiệu ra ngoài vùng nốt.

PatchGAN Critic được huấn luyện theo mục tiêu WGAN-GP. Hàm mất mát của Critic được viết như sau:

$$L_D = E_{\tilde{x}\sim P_g}[D(\tilde{x})] - E_{x\sim P_r}[D(x)] + \lambda_{GP} E_{\hat{x}\sim P_\hat{x}}[(||\nabla_\{\hat{x}\} D(\hat{x})||_2 - 1)^2] \quad (15)$$

Trong đó P_r là phân phối dữ liệu tham chiếu, P_g là phân phối dữ liệu sinh bởi Generator và λ_GP là hệ số gradient penalty. Thành phần này giúp ổn định quá trình huấn luyện đối kháng và tăng tính nhất quán hình thái của mặt nạ dự đoán.

Nhánh Heatmap Detector được tối ưu bằng tổ hợp các loss định vị và xác thực ứng viên:

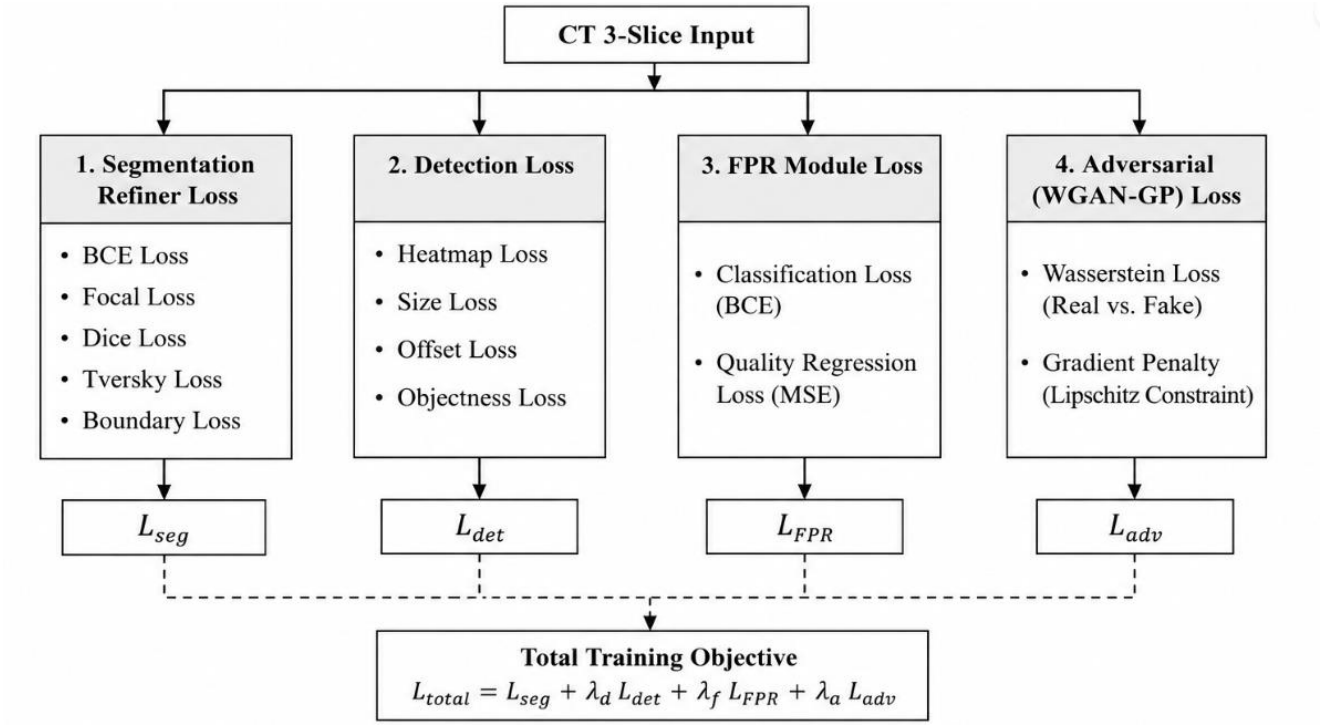
$$L_{det} = \delta_1 L_{heat} + \delta_2 L_{size} + \delta_3 L_{offset} + \delta_4 L_{obj} \quad (16)$$

Trong đó L_heat là CenterNet-style focal heatmap loss, L_size và L_offset là Smooth L1 loss cho kích thước và độ lệch cục bộ của vùng ứng viên, còn L_obj là objectness loss dùng để phân biệt lát có nốt và lát không có nốt được chú thích.

Nhánh False Positive Reduction được huấn luyện bằng loss phân loại kết hợp với hồi quy chất lượng ứng viên:

$$L_{FPR} = L_{cls} + \eta L_{quality} \quad (17)$$

Trong đó L_cls là binary cross-entropy loss cho phân loại ứng viên thật/giả, L_quality là L1 loss giữa quality score dự đoán và quality target, còn η là hệ số trọng số của thành phần quality regression. Trong cấu hình hiện tại, η = 0.35.



Hình 5. Các thành phần hàm mất mát của hệ thống đề xuất

Hình 5 minh họa các nhóm hàm mất mát chính được sử dụng trong quá trình huấn luyện hệ thống. Thay vì tối ưu toàn bộ pipeline bằng một mục tiêu duy nhất, mỗi nhánh được thiết kế với một tập hàm mất mát riêng phù hợp với nhiệm vụ tương ứng. Nhánh Segmentation Refiner tập trung cải thiện độ chồng lấp giữa mặt nạ dự đoán và mặt nạ tham chiếu, đồng thời tăng độ nhạy đối với vùng biên của nốt phổi. Nhánh Detection được tối ưu để xác định chính xác vị trí và kích thước của các vùng ứng viên trên ảnh CT toàn lát.

Bên cạnh đó, nhánh False Positive Reduction sử dụng các hàm mất mát phân loại và hồi quy chất lượng nhằm loại bỏ các ứng viên không tương ứng với nốt phổi thực. Đối với thành phần WGAN-GP, Wasserstein loss kết hợp gradient penalty được sử dụng để ổn định quá trình học đối kháng và tăng tính nhất quán hình thái của kết quả sinh ra. Sự kết hợp của các

nhóm hàm mất mát này giúp hệ thống đồng thời tối ưu khả năng phân đoạn, phát hiện ứng viên và giảm false positive, góp phần nâng cao hiệu năng của toàn bộ pipeline.

Bảng 3. Tóm tắt các hàm mất mát theo từng nhánh.

Nhánh	Loss chính	Mục tiêu
Segmentation Refiner	BCE, Focal, Dice, Tversky, Boundary	Tối ưu chồng lấp, foreground và biên nốt
WGAN-GP	Wasserstein objective, gradient penalty	Tăng tính nhất quán hình thái và sinh heterogeneity map
Heatmap Detector	Heatmap, size, offset, objectness	Định vị candidate regions trên full-slice CT
FPR	Classification, quality regression	Xác thực candidate/component và giảm false positive
Safe Fusion	Validation-calibrated selection	Hợp nhất đầu ra cuối với ràng buộc an toàn

Bảng 3 cho thấy mỗi nhánh trong hệ thống được tối ưu bằng một nhóm hàm mất mát riêng thay vì sử dụng một hàm mất mát thống nhất cho toàn bộ pipeline. Cách thiết kế này cho phép từng thành phần tập trung học các đặc trưng phù hợp với nhiệm vụ của mình, bao gồm phân đoạn nốt phổi, phát hiện vùng ứng viên và xác thực false positive.

Đối với nhánh Segmentation Refiner, các hàm mất mát dựa trên độ chồng lấp và chất lượng biên được sử dụng nhằm cải thiện khả năng tái tạo hình dạng và ranh giới của nốt phổi. Trong khi đó, nhánh Detection tập trung vào bài toán định vị thông qua các thành phần heatmap, kích thước và offset. Nhánh FPR được tối ưu để phân biệt giữa ứng viên thật và ứng viên giả, góp phần giảm số lượng false positive trong kết quả cuối cùng.

Ngoài các thành phần trên, cơ chế học đối kháng WGAN-GP đóng vai trò bổ trợ trong quá trình huấn luyện bằng cách tăng tính nhất quán hình thái của các kết quả dự đoán và hỗ trợ sinh bản đồ intra-nodular heterogeneity. Sự phối hợp giữa các nhóm hàm mất mát khác nhau giúp hệ thống đồng thời tối ưu khả năng phân đoạn, phát hiện và xác thực ứng viên, từ đó nâng cao độ ổn định và hiệu quả của toàn bộ pipeline.

III. Thực nghiệm

A. Dữ liệu và giao thức đánh giá

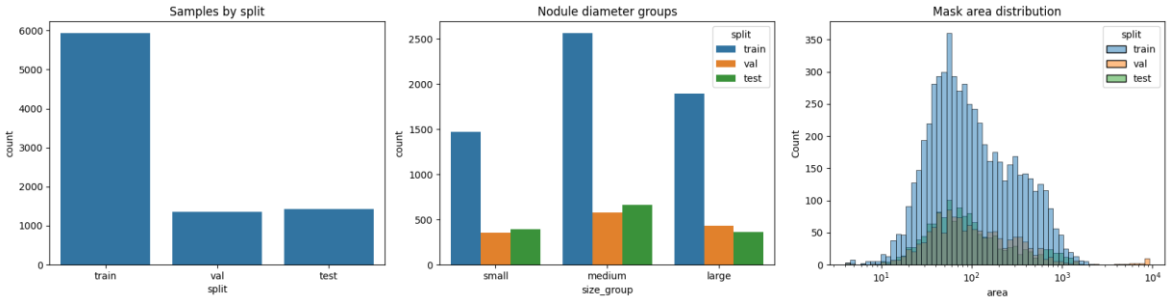
Thực nghiệm được thực hiện trên bộ dữ liệu LIDC-IDRI. Mỗi mẫu đầu vào gồm ba lát CT liên tiếp, trong đó lát trung tâm là lát cần phân đoạn. Ảnh CT được chuẩn hóa theo cửa sổ HU từ -1024 đến 400, sau đó đưa về miền [0, 1]. Mặt nạ tham chiếu được xây dựng từ contour chú thích của LIDC-IDRI trên lát trung tâm. Các lát không có nốt được chú thích được dùng như mẫu nền/negative samples cho huấn luyện detector và FPR, không được diễn giải là dữ liệu bệnh nhân khỏe mạnh.

Dữ liệu được chia theo bệnh nhân để tránh rò rỉ thông tin giữa train, validation và test. Tập test được khóa trong giai đoạn đánh giá cuối, còn validation được dùng để chọn ngưỡng, hiệu chỉnh threshold theo kích thước nốt, hiệu chỉnh safe fusion và chọn đầu ra báo cáo. Hệ thống báo cáo định lượng chính trên mặt nạ complete auto-ROI fusion được chọn theo validation; các chỉ số ROI/refiner được xem là upper-bound hoặc ablation vì trong phần này ROI được sinh từ chú thích khi đánh giá riêng refiner.

Bảng 4. Thống kê dữ liệu LIDC-IDRI sau tiền xử lý và chia tập.

Tập dữ liệu	Số bệnh nhân	Số mẫu có nốt	Số negative samples cho detector/FPR
Train	418	5.934	1.696
Validation	89	1.360	356
Test	91	1.428	372

Bảng 4 cho thấy tập test gồm 1.428 mẫu có nốt từ 91 bệnh nhân và 372 mẫu nền không có nốt được chú thích. Việc tách theo bệnh nhân giúp kết quả phản ánh khả năng tổng quát hóa tốt hơn so với chia ngẫu nhiên theo lát cắt.



Hình 6. Thống kê dữ liệu và phân bố mẫu sau tiền xử lý trong lần chạy thực nghiệm cuối.

Hình 6 trực quan hóa quy mô train/validation/test và phân bố dữ liệu sau khi cache được tạo. Hình này hỗ trợ kiểm tra nhanh tính cân bằng tương đối giữa các tập và xác nhận rằng đánh giá test được thực hiện trên split độc lập theo bệnh nhân.

B. Cấu hình huấn luyện

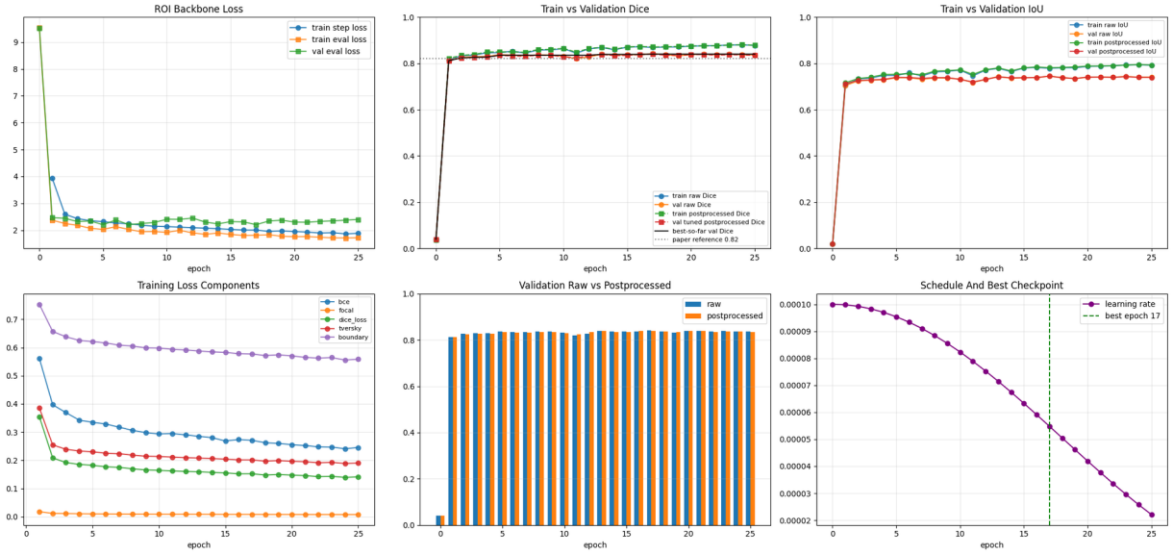
Mô hình được huấn luyện trên Kaggle GPU Tesla T4 với PyTorch 2.10.0+cu128. Thiết lập chính gồm patch ROI 224 x 224, depth 3 lát, batch size 8, learning rate 1e-4 cho refiner và 36 epoch huấn luyện chính. Các nhánh phụ gồm ROI-WGAN, heatmap detector và FPR candidate reducer được huấn luyện trong giai đoạn LNHG++ 20 epoch. Suy luận có test-time augmentation và các tham số threshold/fusion được chọn trên validation.

Bảng 5. Cấu hình thực nghiệm chính.

Nhóm tham số	Giá trị
Thiết bị	Tesla T4, VRAM 15,6 GB; PyTorch 2.10.0+cu128
Dữ liệu đầu vào	3 lát CT liên tiếp; HU [-1024, 400]; patch ROI 224 x 224
Huấn luyện refiner	Batch 8, 36 epoch, AdamW, learning rate 1e-4, weight decay 2,5e-4

Nhánh LNHG++	ROI-WGAN, heatmap detector, FPR reducer; 20 epoch
Detector auto-ROI	Top-K 12, context 7,0, bbox expand 1,55, min ROI 128, max ROI 448
Safe fusion	wgan_weight 0,04; low_thr_delta 0,03; component_fpr_thr 0,20; max_keep 1

Bảng 5 tóm tắt các tham số ảnh hưởng trực tiếp đến khả năng tái lập. Các thông số này được lấy từ cấu hình và log của lần huấn luyện cuối.



Hình 7. Dashboard huấn luyện và validation của mô hình refiner trong lần chạy cuối.

Hình 7 cho thấy xu hướng hội tụ của quá trình huấn luyện. Dashboard này được dùng để kiểm tra xem mô hình có học ổn định trước khi đánh giá trên tập test khóa hay không.

C. Chỉ số đánh giá

Hiệu năng phân đoạn được đánh giá bằng Dice coefficient, IoU, Boundary F1, HD95, ASSD, sai số tâm và sai số diện tích. Nhánh detector được đánh giá bằng mức chứa ground truth của ROI ứng viên Top-1/Top-3/Top-5 và hit rate theo IoU/center distance. Nhánh FPR được đánh giá bằng AUC, precision, recall và specificity ở ngưỡng 0,50. Các kết quả định lượng được báo cáo riêng theo module để phân biệt lỗi định vị ROI, lỗi phân đoạn biên và lỗi false positive.

Bảng 6. Bộ chỉ số đánh giá trong thực nghiệm.

Nhóm	Chỉ số	Ý nghĩa
Segmentation	Dice, IoU	Đo mức chồng lấp giữa mặt nạ dự đoán và mặt nạ tham chiếu
Boundary	Boundary F1, HD95, ASSD	Đánh giá chất lượng ranh giới và khoảng cách biên
Detector ROI	Top-K contains GT, hit IoU, center error	Đánh giá khả năng đề xuất ROI chứa nốt
FPR	AUC, precision, recall, specificity	Đánh giá phân biệt ứng viên thật/giả và kiểm soát false positive
Reliability	uncertainty entropy,	Ước lượng mức tin cậy của đầu ra để hỗ trợ phân

	needs-review rate	tích lỗi

Bảng 6 cho thấy báo cáo không chỉ dựa vào Dice trung bình. Các chỉ số detector và FPR giúp giải thích vì sao hệ thống đạt hoặc không đạt hiệu năng mong muốn ở từng thành phần.

D. Đánh giá bản đồ heterogeneity

Bản đồ heterogeneity được đánh giá ở phạm vi trực quan hóa thông qua các thống kê như giá trị trung bình, độ lệch chuẩn, entropy, leakage giữa vùng trong/ngoài mask và độ tin cậy. Các thống kê này chỉ phản ánh tính ổn định của bản đồ sinh trong vùng nốt; chúng không được dùng để phân loại lành tính/ác tính, không thay thế radiomics đã kiểm chứng và không tạo kết luận chẩn đoán.

IV. Kết quả

A. Kết quả phân đoạn chính

Đầu ra được chọn cho báo cáo final là complete auto-ROI fusion mask do có Dice validation cao nhất trong các lựa chọn an toàn. Trên tập test, complete two-branch system đạt Dice trung bình 0,8506, IoU trung bình 0,7552 và Boundary F1 trung bình 0,8545. Khoảng tin cậy bootstrap 95% của Dice là [0,8447; 0,8567]. So với ROI backbone, complete system tăng Dice trung bình 0,0006 điểm trên test; mức tăng này nhỏ và không có ý nghĩa thống kê rõ rệt theo Wilcoxon p = 0,9887, nhưng safe fusion giữ được hiệu năng refiner trong khi bổ sung kiểm soát component/FPR và bản đồ trực quan hóa.

Bảng 7. Kết quả ablation của các nhánh trên validation và test.

Mô-đun	Val Dice	Test Dice	Test IoU	Test Boundary F1	Nhận xét
ROI backbone	0,8451	0,8501	0,7547	0,8547	Refiner ổn định khi ROI đúng
Branch 1 ROI-WGAN	0,8366	0,8370	-	-	Tạo xác suất phụ và heterogeneity map
ROI + Branch 1 fusion	0,8453	0,8503	0,7550	0,8555	Blend xác suất được hiệu chỉnh trên validation
Complete two-branch system	0,8460	0,8506	0,7552	0,8545	Đầu ra final được chọn theo validation

Bảng 7 cho thấy refiner là thành phần tạo hiệu năng phân đoạn chính. ROI-WGAN độc lập thấp hơn backbone, nhưng khi được dùng trong fusion cùng FPR và ràng buộc an toàn, hệ thống complete giữ Dice test cao nhất trong các cấu hình được báo cáo.

Ngoài Dice và IoU, complete system đạt HD95 trung bình 4,36 pixel, ASSD trung bình 1,42 pixel, sai số tâm trung bình 1,97 pixel và sai số diện tích trung bình 10,13%. Các chỉ số này cho thấy biên dự đoán nhìn chung bám sát contour tham chiếu, dù sai số diện tích vẫn tồn tại ở một số nốt nhỏ hoặc nốt có biên không rõ.

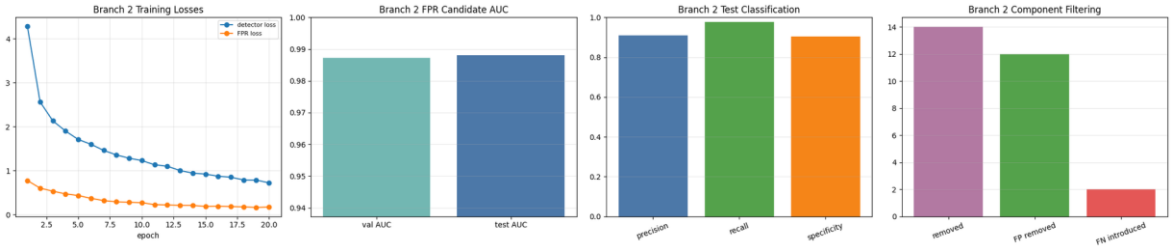
B. Detector ROI và false-positive reduction

Detector ROI được đánh giá theo khả năng đề xuất vùng ứng viên chứa nốt và theo độ bao phủ của các ROI Top-K. Trên tập test, Top-1 ROI chứa ground truth ở 77,52% mẫu, Top-3 đạt 93,14% và Top-5 đạt 96,15%. Điều này cho thấy detector có khả năng bao phủ nốt tốt khi xét nhiều ứng viên, nhưng vẫn cần FPR và cơ chế chọn ROI để giảm ảnh hưởng của ứng viên sai.

Bảng 8. Kết quả detector ROI và FPR trên tập test.

Thành phần	Chỉ số	Giá trị
Detector ROI	Top-1 ROI contains GT	0,7752
Detector ROI	Top-3 ROI contains GT	0,9314
Detector ROI	Top-5 ROI contains GT	0,9615
Detector ROI	Top-5 GT coverage mean	0,9642
Detector ROI	Top-5 hit IoU >= 0,10	0,8039
Detector ROI	Top-5 center error <= 20 px	0,9454
Candidate FPR	AUC	0,9881
Candidate FPR	Precision / Recall / Specificity @ 0,50	0,9100 / 0,9769 / 0,9034
Component FPR	Component removed / FP removed / FN introduced	14 / 12 / 2
Safe fusion	Fallback rate	0,0007

Bảng 8 cho thấy FPR candidate có AUC cao trên test, còn component-level FPR loại được 12 thành phần false positive nhưng cũng gây 2 false negative. Do đó safe fusion là cần thiết để giới hạn tác động bất lợi của việc lọc component quá mạnh.

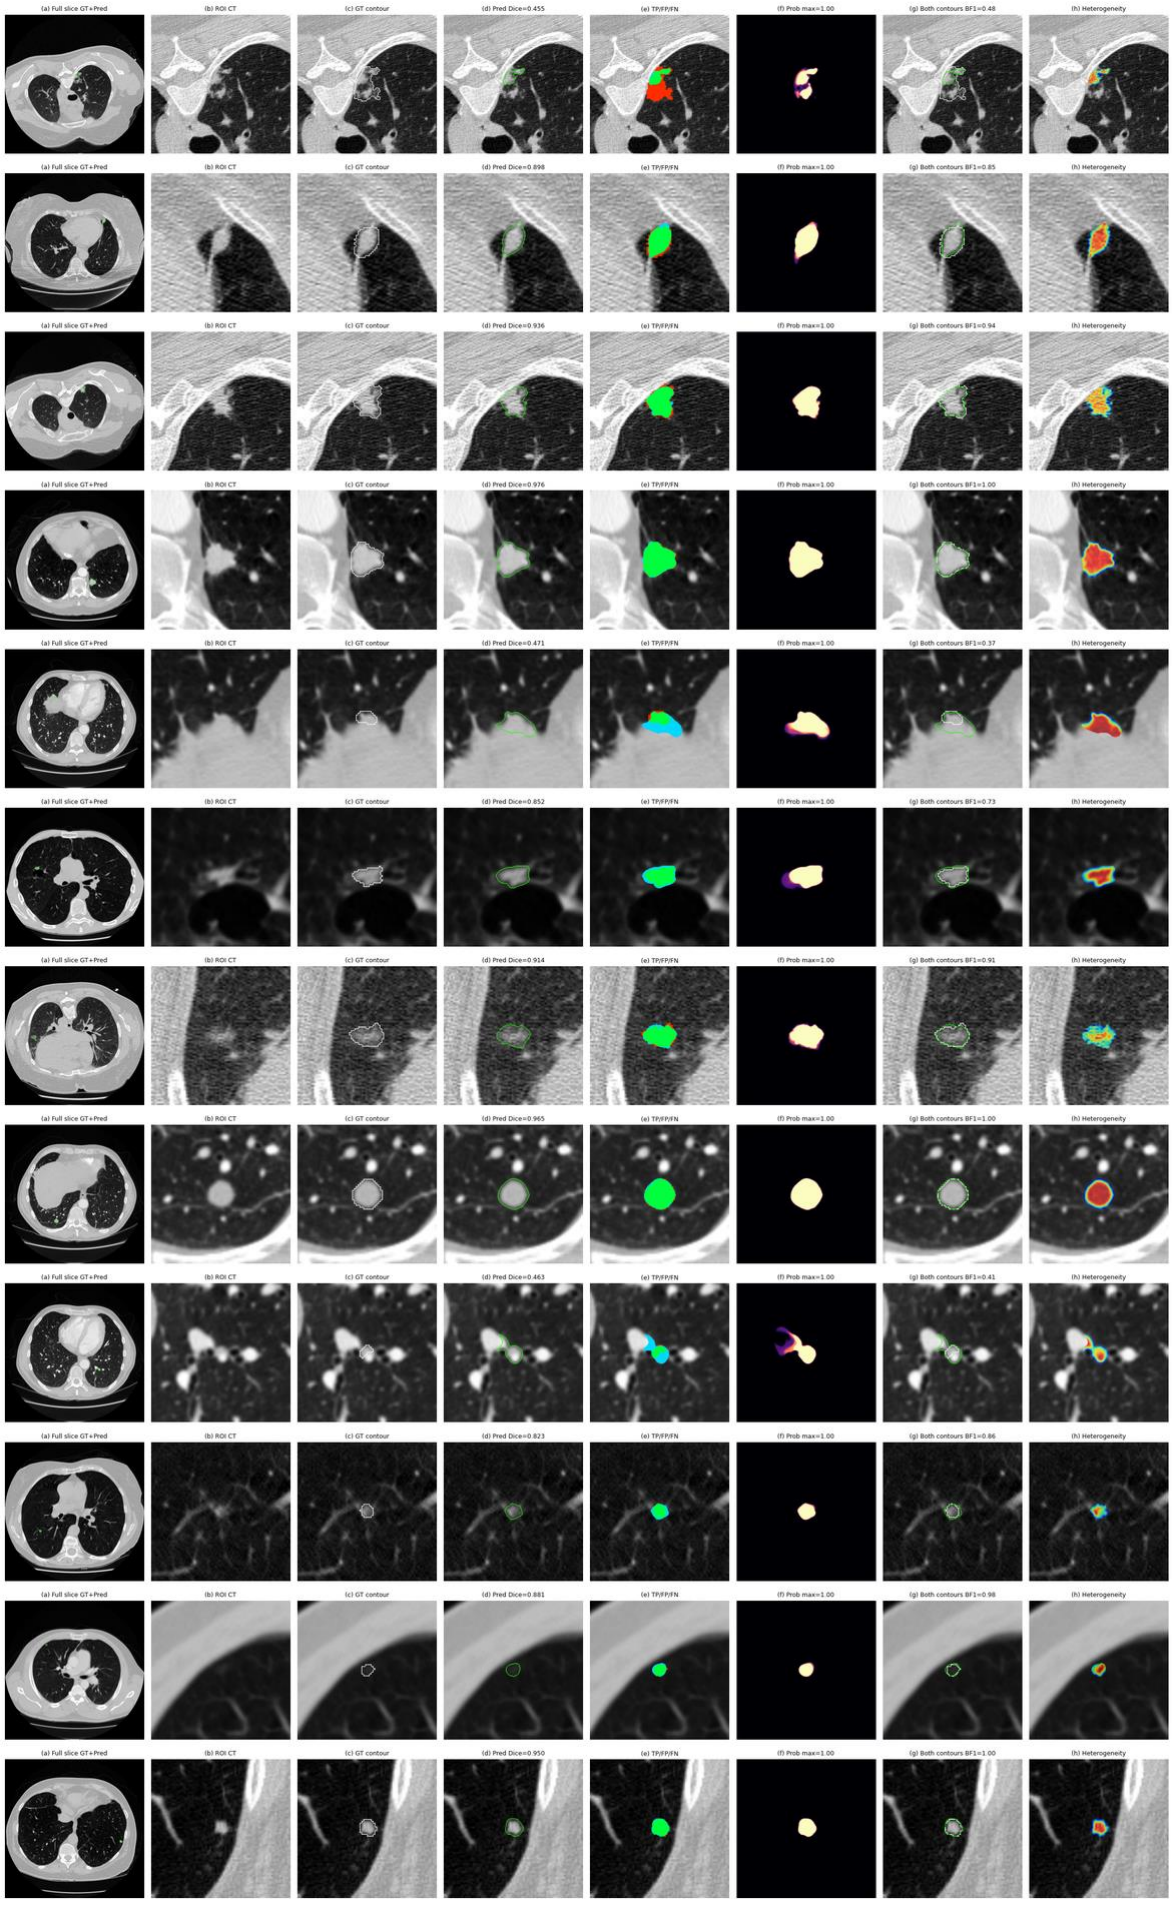


Hình 8. Dashboard đánh giá nhánh FPR candidate trên validation và test.

Hình 8 minh họa sự tách biệt điểm số giữa candidate thật và candidate giả. Kết quả AUC cao trong Hình 8 phù hợp với các chỉ số ở Bảng 8, nhưng FPR vẫn cần được đặt sau ràng buộc safe fusion để tránh xóa nhầm nốt thật.

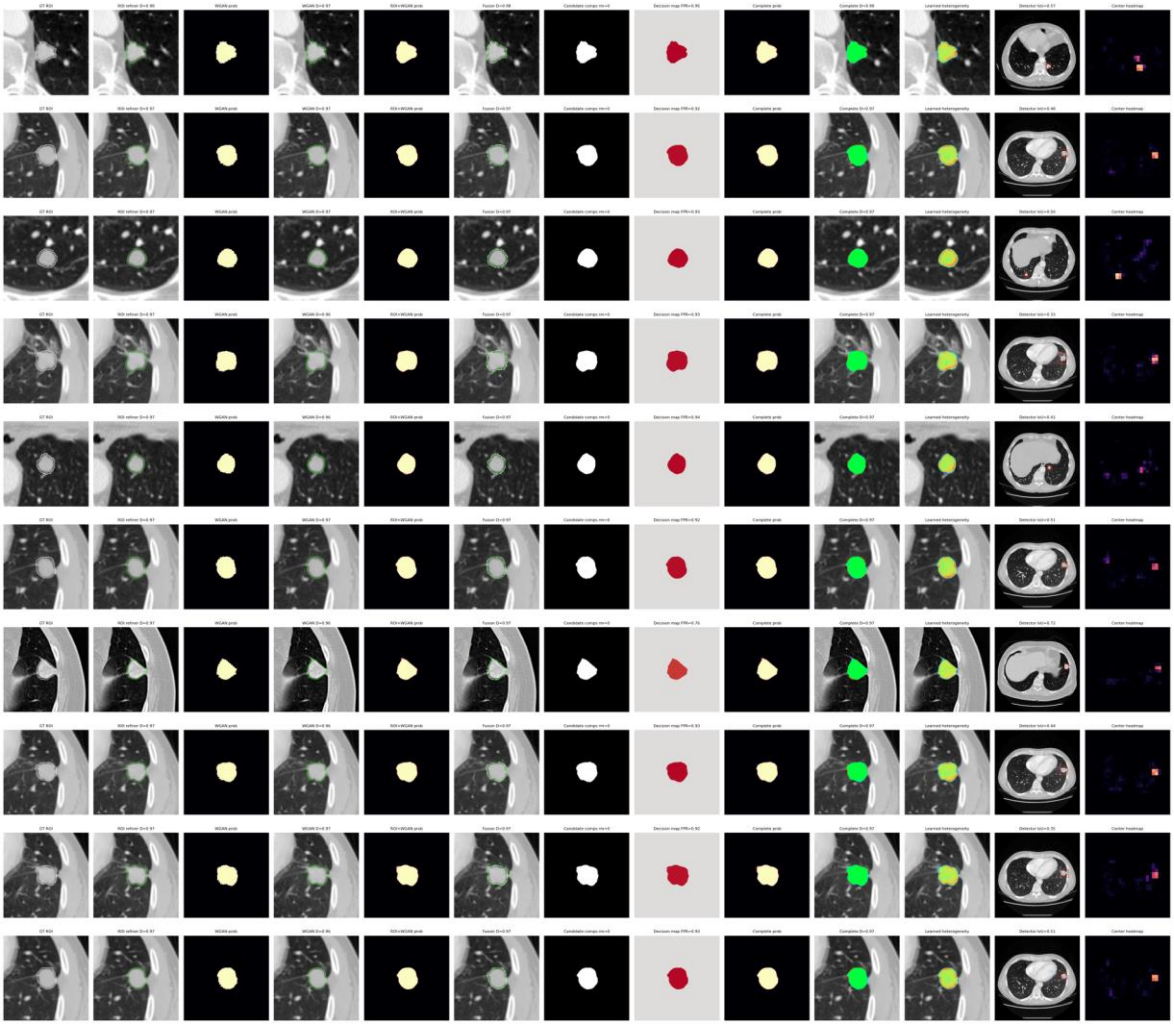
C. Kết quả định tính và trực quan hóa

Các hình định tính được lấy từ đầu ra của lần đánh giá test cuối. Mục tiêu của phần này là kiểm tra xem các chỉ số định lượng có tương ứng với chất lượng mặt nạ trên ảnh CT hay không, đồng thời quan sát các trường hợp nốt nhỏ, nốt biên mờ hoặc vùng có cấu trúc giải phẫu phức tạp.


(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.455
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.48
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.898
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.85
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.936
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.94
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.976
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=1.00
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.471
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.37
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.852
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.73
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.914
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.91
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.965
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=1.00
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.463
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.41
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.823
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.86
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.881
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=0.98
(h) Heterogeneity
(a) Full slice GT+Pred
(b) ROI CT
(c) GT contour
(d) Pred Dice=0.950
(e) TP/FP/FN
(f) Prob max=1.00
(g) Both contours BF1=1.00
(h) Heterogeneity

Hình 9. Một số kết quả phân đoạn đại diện trên tập test.

Hình 9 trình bày lát CT, ROI, contour ground truth, mặt nạ dự đoán, bản đồ xác suất và bản đồ TP/FP/FN. Các mẫu đại diện cho thấy refiner thường bám tốt vùng nốt, trong khi sai khác còn lại chủ yếu nằm ở rìa biên hoặc ở vùng có cấu trúc tương tự nốt.



Hình 10. Minh họa complete two-branch fusion và quyết định giữ/loại component.

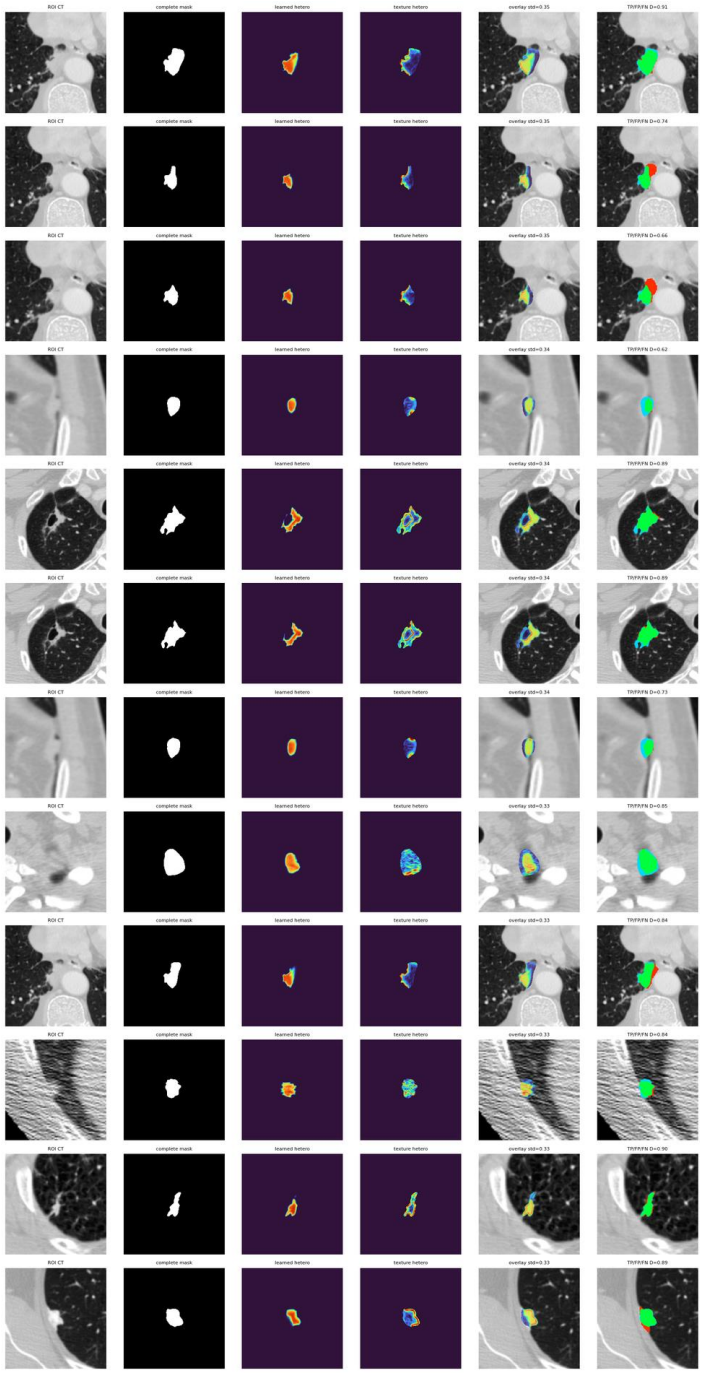
Hình 10 phóng to luồng xử lý complete system gồm ROI-WGAN probability, fusion probability, component FPR decision, complete probability và learned heterogeneity. Hình này giải thích vì sao kết quả final không chỉ là output của một mạng segmentation đơn lẻ mà là kết quả hợp nhất có kiểm soát.

Bảng 9. Thống kê heterogeneity và reliability trên tập test.

Chỉ số	Giá trị	Diễn giải
Heterogeneity mean	0,3929	Mức đáp ứng trung bình trong bản đồ dị thể
Heterogeneity std	0,2113	Mức biến thiên tương đối trong vùng nốt
Heterogeneity entropy	0,8153	Độ phân tán của đáp ứng heterogeneity
Inside/outside leakage	0,0066	Mức rò tín hiệu ra ngoài vùng nốt thấp
Uncertainty entropy	0,1739	Độ bất định trung bình của xác suất

Reliability score	0,8964	Điểm tin cậy trung bình của complete output
Needs-review rate	1,19%	Tỷ lệ mẫu được gắn cờ cần xem xét

Bảng 9 chỉ phục vụ đánh giá tính ổn định của bản đồ trực quan hóa và độ tin cậy. Các giá trị này không được dùng để suy luận bản chất mô học hoặc chẩn đoán lành tính/ác tính.



Hình 11. Bản đồ heterogeneity sinh bởi nhánh ROI-WGAN trên các mẫu test.

Hình 11 cho thấy learned heterogeneity map được giới hạn trong vùng nốt dự đoán và có thể làm nổi bật các vùng có biến thiên cường độ hoặc texture tương đối. Hình này cần được đọc như lớp visualization bổ sung, không phải kết quả phân loại hoặc tiên lượng lâm sàng.

V. Thảo luận

Kết quả thực nghiệm cho thấy refiner ROI là thành phần quyết định hiệu năng phân đoạn, đạt Dice test khoảng 0,8501. Complete two-branch system đạt Dice 0,8506, cao hơn ROI backbone rất nhỏ và không có ý nghĩa thống kê rõ rệt. Vì vậy, đóng góp của complete system không nên được diễn giải là cải thiện Dice lớn, mà là bổ sung một cơ chế hợp nhất có kiểm soát giữa refiner, WGAN probability, component FPR và safe fusion để giữ hiệu năng ổn định trong khi cung cấp thêm thông tin trực quan hóa.

Nhánh ROI-WGAN có Dice độc lập thấp hơn refiner, nhưng vẫn có vai trò trong hệ thống. Thứ nhất, xác suất WGAN được dùng với trọng số nhỏ trong fusion, giúp bổ sung tín hiệu phụ khi validation cho phép. Thứ hai, heterogeneity head tạo bản đồ visualization bám theo vùng nốt và có leakage thấp. Thứ ba, PatchGAN critic và teacher consistency hỗ trợ học biểu diễn hình thái nốt ở mức ROI. Tuy nhiên, vì chưa có nhãn mô học hoặc đánh giá đa trung tâm, bản đồ heterogeneity chỉ được trình bày như kết quả quan sát, không phải biomarker đã kiểm chứng.

Nhánh detector ROI đạt Top-5 containment 96,15% trên test, cho thấy phần lớn nốt thật nằm trong tập ROI ứng viên. Đây là điều kiện cần để tự động hóa pipeline, nhưng chưa đủ để bảo đảm toàn bộ hệ thống tự động đạt hiệu năng tương đương ROI đã biết. Vì vậy, báo cáo final tách riêng kết quả detector coverage khỏi kết quả mặt nạ complete fusion. Cách trình bày này trung thực hơn với dữ liệu: detector có độ bao phủ cao, FPR có AUC cao, còn mặt nạ final có Dice cao trong thiết lập complete fusion được chọn theo validation.

FPR candidate đạt AUC 0,9881 trên test, precision 0,9100, recall 0,9769 và specificity 0,9034 ở ngưỡng 0,50. Điều này cho thấy mạng FPR học được khác biệt rõ giữa candidate thật và giả. Tuy nhiên, component-level FPR vẫn tạo 2 false negative trong test, nên việc lọc component không thể thực hiện một cách tham lam. Safe fusion và fallback rate thấp cho thấy cơ chế bảo vệ đã hạn chế thay đổi quá mức so với refiner, nhưng các trường hợp lỗi vẫn cần phân tích riêng trong các lần phát triển tiếp theo.

Hạn chế chính của thực nghiệm là chỉ dùng LIDC-IDRI và chưa có kiểm chứng ngoài tập dữ liệu. Đánh giá Dice cao của refiner/complete fusion dựa trên ROI được xây dựng từ chú thích khi phân tích ablation, do đó phản ánh upper-bound của module segmentation khi vùng nốt đã được cô lập tốt. Để tiến gần hơn đến triển khai end-to-end, cần cải thiện lựa chọn ROI tự động, hiệu chỉnh objectness/no-nodule decision, đánh giá trên dữ liệu CT đa trung tâm và kiểm tra độ ổn định theo độ dày lát cắt, kernel tái tạo, loại nốt và kích thước nốt.

VI. Kết luận

Báo cáo đã hoàn thiện hệ thống phân đoạn nốt phổi CT theo kiến trúc detector-refiner-fusion có tham chiếu từ LNHG. Trên tập test LIDC-IDRI, complete two-branch system được chọn theo validation đạt Dice 0,8506, IoU 0,7552 và Boundary F1 0,8545; ROI backbone đạt

Dice 0,8501; ROI-WGAN độc lập đạt Dice 0,8370; còn ROI + Branch 1 fusion đạt Dice 0,8503. Nhánh FPR candidate đạt AUC 0,9881, trong khi detector ROI đạt Top-5 containment 96,15%, cho thấy các module phụ trợ có giá trị trong định vị ứng viên và kiểm soát false positive.

Kết quả cũng cho thấy cần diễn giải hệ thống một cách thận trọng. Complete fusion cải thiện Dice ở mức nhỏ so với ROI backbone, còn heterogeneity map chỉ là lớp trực quan hóa trong vùng nốt, không phải công cụ chẩn đoán. Hướng phát triển tiếp theo là nâng độ tin cậy của detector ROI, tối ưu chọn candidate trên lát không có nốt được chú thích, bổ sung đánh giá ngoài LIDC-IDRI và mở rộng đánh giá theo kiểu 3D/đa lát để tăng tính ổn định theo ngữ cảnh không gian.

Tài liệu tham khảo

[1] J. Song et al., "Automatic Lung Nodule Segmentation and Intra-Nodular Heterogeneity Image Generation," IEEE Journal of Biomedical and Health Informatics, vol. 26, no. 6, pp. 2570-2581, Jun. 2022, doi: 10.1109/JBHI.2021.3135647.

[2] H. Sung et al., "Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries," CA: A Cancer Journal for Clinicians, vol. 71, no. 3, pp. 209-249, 2021.

[3] A. Kumar, M. Fulham, D. Feng, and J. Kim, "Co-learning feature fusion maps from PET-CT images of lung cancer," IEEE Transactions on Medical Imaging, vol. 39, no. 1, pp. 204-217, Jan. 2020, doi: 10.1109/TMI.2019.2923601.

[4] G. Wu et al., "Sparse representation-based radiomics for the diagnosis of brain tumors," IEEE Transactions on Medical Imaging, vol. 37, no. 4, pp. 893-905, Apr. 2018, doi: 10.1109/TMI.2017.2776967.

[5] J. Song et al., "A new approach to predict progression-free survival in stage IV EGFR-mutant NSCLC patients with EGFR-TKI therapy," Clinical Cancer Research, vol. 24, no. 15, pp. 3583-3592, Aug. 2018, doi: 10.1158/1078-0432.CCR-17-2507.

[6] T. Messay, R. C. Hardie, and T. R. Tuinstra, "Segmentation of pulmonary nodules in computed tomography using a regression neural network approach and its application to the LIDC-IDRI dataset," Medical Image Analysis, vol. 22, no. 1, pp. 48-62, May 2015, doi: 10.1016/j.media.2015.02.002.

[7] J. Song et al., "Lung lesion extraction using a toboggan based growing automatic segmentation approach," IEEE Transactions on Medical Imaging, vol. 35, no. 1, pp. 337-353, Jan. 2016, doi: 10.1109/TMI.2015.2474119.

[8] M. M. Farhangi, H. Frigui, A. Seow, and A. Amini, "3-D active contour segmentation based on sparse linear combination of training shapes (SCoTS)," IEEE Transactions on Medical Imaging, vol. 36, no. 11, pp. 2239-2249, Nov. 2017, doi: 10.1109/TMI.2017.2720119.

[9] S. Wang et al., "Central focused convolutional neural networks: Developing a data-driven model for lung nodule segmentation," Medical Image Analysis, vol. 40, pp. 172-183, Aug. 2017, doi: 10.1016/j.media.2017.06.014.

[10] X. Xu et al., "MSCS-DeepLN: Evaluating lung nodule malignancy using multi-scale cost-sensitive neural networks," Medical Image Analysis, vol. 65, 2020, Art. no. 101772.

[11] S. Napel, W. Mu, B. V. Jardim-Perassi, H. J. Aerts, and R. J. Gillies, "Quantitative imaging of cancer in the postgenomic era: Radiomics, deep learning, and habitats," Cancer, vol. 124, no. 24, pp. 4633-4649, 2018.

[12] A. Traverso, L. Wee, A. Dekker, and R. Gillies, "Repeatability and reproducibility of radiomic features: A systematic review," International Journal of Radiation Oncology, Biology, Physics, vol. 102, no. 4, pp. 1143-1158, Nov. 2018, doi: 10.1016/j.ijrobp.2018.05.053.

[13] S. G. Armato III et al., "The lung image database consortium (LIDC) and image database resource initiative (IDRI): A completed reference database of lung nodules on CT scans," Medical Physics, vol. 38, no. 2, pp. 915-931, Feb. 2011, doi: 10.1118/1.3528204.

[14] Y. J. Kim, S. H. Lee, K. Y. Lim, and K. G. Kim, "Development and validation of segmentation method for lung cancer volumetry on chest CT," Journal of Digital Imaging, vol. 31, no. 4, pp. 505-512, Aug. 2018, doi: 10.1007/s10278-018-0051-5.

[15] H. Shakir, T. M. Rasool Khan, and H. Rasheed, "3-D segmentation of lung nodules using hybrid level sets," Computers in Biology and Medicine, vol. 96, pp. 214-226, May 2018, doi: 10.1016/j.compbiomed.2018.03.015.

[16] S. Mukhopadhyay, "A segmentation framework of pulmonary nodules in lung CT images," Journal of Digital Imaging, vol. 29, no. 1, pp. 86-103, Feb. 2016, doi: 10.1007/s10278-015-9801-9.

[17] Y. Gu et al., "Automatic lung nodule detection using multi-scale dot nodule-enhancement filter and weighted support vector machines in chest computed tomography," PLoS One, vol. 14, no. 1, 2019, Art. no. e0210551.

[18] X. Huang, W. Sun, T. B. Tseng, C. Li, and W. Qian, "Fast and fully-automated detection and segmentation of pulmonary nodules in thoracic CT scans using deep convolutional neural networks," Computerized Medical Imaging and Graphics, vol. 74, pp. 25-36, Jun. 2019, doi: 10.1016/j.compmedimag.2019.02.003.

[19] H. Tang, C. Zhang, and X. Xie, "NoduleNet: Decoupled false positive reduction for pulmonary nodule detection and segmentation," in Proc. Medical Image Computing and Computer-Assisted Intervention, 2019, pp. 266-274.

[20] Y. Li and L. Shen, "cC-GAN: A robust transfer-learning framework for HEp-2 specimen image segmentation," IEEE Access, vol. 6, pp. 14048-14058, 2018, doi: 10.1109/ACCESS.2018.2808938.

[21] X. Dong et al., "Automatic multiorgan segmentation in thorax CT images using U-net-GAN," Medical Physics, vol. 46, no. 5, pp. 2157-2168, 2019, doi: 10.1002/mp.13458.

[22] C. Zhao, J. Han, Y. Jia, and F. Gou, "Lung nodule detection via 3D U-Net and contextual convolutional neural network," in Proc. Int. Conf. Networking and Network Applications, 2018, pp. 356-361, doi: 10.1109/NANA.2018.8648753.

[23] I. J. Goodfellow et al., "Generative adversarial nets," in Proc. Advances in Neural Information Processing Systems, 2014, pp. 2672-2680.

[24] M. Arjovsky, S. Chintala, and L. Bottou, "Wasserstein GAN," 2017, arXiv:1701.07875.

[25] I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, and A. C. Courville, "Improved training of Wasserstein GANs," in Proc. Advances in Neural Information Processing Systems, 2017, pp. 5767-5777.

[26] D. Zhou et al., "IoU loss for 2D/3D object detection," in Proc. IEEE International Conference on 3D Vision, 2019, pp. 85-94, doi: 10.1109/3DV.2019.00019.

[27] H. Rezatofighi et al., "Generalized intersection over union: A metric and a loss for bounding box regression," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019, pp. 658-666, doi: 10.1109/CVPR.2019.00075.

[28] Y. Wang, X. Ning, B. Leng, and H. Fu, "Ship detection based on deep learning," in Proc. IEEE International Conference on Mechatronics and Automation, 2019, pp. 275-279, doi: 10.1109/ICMA.2019.8816265.

[29] K. Lin et al., "Face detection and segmentation based on improved Mask R-CNN," Discrete Dynamics in Nature and Society, vol. 2020, 2020, Art. no. 9242917, doi: 10.1155/2020/9242917.

[30] M. Hassanin, S. Khan, and M. Tahtali, "A new localization objective for accurate fine-grained affordance segmentation under high-scale variations," IEEE Access, vol. 8, pp. 28123-28132, 2019, doi: 10.1109/ACCESS.2019.2958608.

[31] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 39, no. 6, pp. 1137-1149, Jun. 2016.

[32] R. Wang, W. Zhang, W. Nie, and Y. Yu, "Gastric polyps detection by improved Faster R-CNN," in Proc. 8th International Conference on Computer and Pattern Recognition, 2019, pp. 128-133.

[33] Q. Yang et al., "Low-dose CT image denoising using a generative adversarial network with Wasserstein distance and perceptual loss," IEEE Transactions on Medical Imaging, vol. 37, no. 6, pp. 1348-1357, Jun. 2018.

[34] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," 2014, arXiv:1409.1556.

[35] F. Isensee, P. F. Jaeger, S. A. Kohl, J. Petersen, and K. H. Maier-Hein, "nnU-Net: A self-configuring method for deep learning-based biomedical image segmentation," Nature Methods, vol. 18, no. 2, pp. 203-211, 2021.

[36] A. P. Reeves and A. Biancardi, "The lung image database consortium (LIDC) nodule size report," Cornell University Vision and Image Analysis Group, Tech. Rep., 2011, pp. 10-27.

[37] R. Zhang et al., "Automatic segmentation of acute ischemic stroke from DWI using 3-D fully convolutional DenseNets," IEEE Transactions on Medical Imaging, vol. 37, no. 9, pp. 2149-2160, Sep. 2018, doi: 10.1109/TMI.2018.2821244.

[38] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in Proc. Medical Image Computing and Computer-Assisted Intervention, 2015, pp. 234-241.

[39] S. H. Khan, M. Hayat, and F. Porikli, "Regularization of deep neural networks with spectral dropout," Neural Networks, vol. 110, pp. 82-90, 2019, doi: 10.1016/j.neunet.2018.09.009.

[40] X. Huang, J. Shan, and V. Vaidya, "Lung nodule detection in CT using 3D convolutional neural networks," in Proc. IEEE 14th International Symposium on Biomedical Imaging, 2017, pp. 379-383, doi: 10.1109/ISBI.2017.7950542.

[41] E. Sala et al., "Unravelling tumour heterogeneity using next-generation imaging: Radiomics, radiogenomics, and habitat imaging," Clinical Radiology, vol. 72, no. 1, pp. 3-10, Jan. 2017, doi: 10.1016/j.crad.2016.09.013.

[42] D. Fehr et al., "Automatic classification of prostate cancer Gleason scores from multiparametric magnetic resonance images," Proceedings of the National Academy of Sciences, vol. 112, no. 46, pp. E6265-E6273, 2015, doi: 10.1073/pnas.1505935112.

[43] M.-C. Desseroit et al., "Reliability of PET/CT shape and heterogeneity features in functional and morphologic components of non-small cell lung cancer tumors: A repeatability analysis in a prospective multicenter cohort," Journal of Nuclear Medicine, vol. 58, no. 3, pp. 406-411, 2017.

[44] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, "Focal loss for dense object detection," in Proc. IEEE International Conference on Computer Vision, 2017, pp. 2980-2988.

[45] S. S. M. Salehi, D. Erdogmus, and A. Gholipour, "Tversky loss function for image segmentation using 3D fully convolutional deep networks," in Proc. Machine Learning in Medical Imaging, 2017, pp. 379-387.

[46] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in Proc. International Conference on Learning Representations, 2019.